

Bases de Dades Avançades

Carlos Arbonés and Juan P. Zaldivar

GCED, UPC.
Apunts.

Contents

1 Data Warehousing	4
1.1 Operational vs Analytical Data	4
1.2 Single-layer architecture	4
1.3 Data Sources	5
1.4 Definition of Data Warehouse	5
1.5 Data Marts	5
1.6 Two-layer architecture	6
1.7 Three-layer architecture	7
1.8 Metadata	7
2 Multidimensional modeling	8
2.1 FASMI test	8
2.2 Real World	9
2.3 Conceptual World	10
2.3.1 Types of schemas	10
2.4 Representation World	11
2.4.1 MOLAP: Multidimensional Matrix	11
2.4.2 ROLAP	11
2.4.3 Comparison of Desing Steps: OLTP vs OLAP	12
2.4.4 HOLAP	13
3 Advanced Multidimensional Design	14
3.1 Algebraic operations	14
3.2 Advanced Design	14
3.3 Aggregation Problems	16
4 Extract, Transform and Load	17
4.1 Definition	17
4.1.1 Extraction	17
4.1.2 Transformation	17
4.1.3 Load	18
4.2 ETL Steps	19
4.2.1 Data extraction mechanisms	20
4.2.2 Kinds of transformation tasks	21
4.3 ETL process design	22
4.3.1 ETL tools GUI	22
4.3.2 Hand-coded ETL	22
4.3.3 ETL process quality	23
4.4 Architectual setting	23
4.4.1 Data flow	23
4.4.2 Control flow	24
4.4.3 Staging area	24
4.4.4 Metadata managment	24
4.5 ETL operations	25
4.5.1 Non-Blocking Example	26
4.5.2 Blocking Example	26
4.5.3 Blocking optimized Example	27
4.5.4 List of blocking and Non-blocking operations	27
5 Data Quality	28
5.1 Data Conflicts	29

5.2	Quality Measures	29
5.2.1	Completeness	29
5.2.2	Accuracy	30
5.2.3	Timeliness (Freshness)	30
5.2.4	Consistency	30
5.2.5	Trade-offs between dimensions	31
5.3	Quality Rules	31
5.3.1	Restricciones de integridad en RDBMS	31
5.3.2	Problems in the rules	32
5.3.3	Fine-tuning imperfections	32
5.4	Quality improvement	33
5.4.1	Process for Object identification	33
5.4.2	Search space reduction	34
5.4.3	Comparison/Similarity function	34
6	Schema and Data Integration	35
6.1	BD distribuida	36
6.2	Kinds of Heterogeneity	37
6.2.1	Schema and instances	37
6.2.2	Intra-class heterogeneity	37
6.2.3	Inter-class heterogeneity	38
6.2.4	Data-Metadata heterogeneity	38
6.3	Overcoming System Heterogeneity	39
6.4	Schema Integration	39
6.4.1	Alignment Process	39
6.4.2	Mapping	40
6.4.3	Exampte of Global as View (GAV)	41
6.5	Data Integration	42
6.5.1	Entity resolution	42
6.5.2	Algoritmo R-Swoosh	42
7	Sessió de dubtes	43
A	Theoretical questions	46
B	OLAP and the Multidimensional Model	48
B.1	Theoretical questions	48
B.2	Problems	49
C	Extraction, Transformation and Load	57
C.1	Theoretical questions	57
C.2	Problems	57
D	Data Quality	59
D.1	Problems	59
E	Schema and Data Integration	65
E.1	Theoretical questions	65
E.2	Problems	65

1 Data Warehousing

1.1 Operational vs Analytical Data

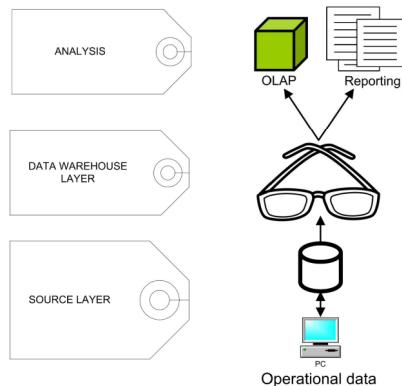
Lo primero que tenemos que darnos cuenta es separar entre datos operacionales y datos analíticos. Los datos operacionales son los del día a día de la empresa, los que utilizamos para gestionar el negocio. Los datos analíticos son los que utilizamos para tomar decisiones respecto nuestro negocio (son de naturaleza temporal).

- **Evolución:** para ver el día a día solo nos importan los datos de hoy. En cambio para tomar decisiones necesitamos datos antiguos y gestionar la evolución que han sufrido en distintos ámbitos de la empresa.
- **Volúmenes de datos:** el hecho de guardar datos históricos para analizar su evolución hace que crezca el volumen de datos.
- **Niveles de agregación:** Por otro lado, cuando tomamos decisiones no miramos los datos de un solo cliente sino que miramos los datos agregados. P.e los datos de nuestros clientes en una cierta región, en un cierto año, etc.
- **Actualización:** Los datos no tienen porqué estar completamente actualizados. Lo que nos interesa es ver la evolución histórica y por un dato que falte no pasa nada grave. En cambio para datos operacionales si que es importante. P.e no podemos sacar dinero de un banco si no tenemos el saldo de ayer actualizado.
- **Tiempo de respuesta:** Tenemos muchos datos, lo que impacta al tiempo de respuesta. Siempre es importante pero a ciertas escalas es más crítico. Menor el número de usuarios.
- **Usuarios:** Normalmente, el tipo de usuarios que tenemos en un sistema decisional/de análisis son los ejecutivos de la empresa.
- **Funcionalidad:** Operacional o de análisis.

1.2 Single-layer architecture

Tenemos datos operacionales y a partir de estos generamos una vista (nivel virtual) que nos permite alimentar nuestras herramientas OLAP o de *query reporting*. Los datos pasan por un filtro que los reorganiza de la forma más adecuada para estas herramientas.

Únicamente tenemos nuestras fuentes de datos operaciones, no generamos una réplica de estos datos. Esto facilita la gestión y reduce costes (menos infraestructura), el problema es que no guardamos esta réplica de los datos (el histórico se puede ver comprometido en mayor medida según los **data sources** que tengamos).



En general ocasiona problemas a largo y corto plazo. Por eso se opta en la mayoría de los casos por un **Data Warehouse**.

1.3 Data Sources

De más comunes/frecuentes a menos tenemos:

1. **Propios sistemas operacionales de la empresa:** aplicaciones propias que tienen los datos sobre nuestro negocio (RRHH, contabilidad, logística), son conocidas por nosotros y tenemos el control sobre los cambios.
2. **Sistemas de información de nuestros socios:** ya sea de nuestros clientes/proveedores. Podemos llegar a acuerdos de cómo gestionar los datos. No tenemos todo el control pero tenemos una cierta capacidad de negociar como mínimo.
3. **Red Informática Mundial y Redes Sociales:** no tenemos ningún control, puede cambiar cualquier cosa (lo cual es normal). Cada vez que tenemos que tomar una decisión tenemos que ir a esa *web*, pero puede ser que el dato que queremos ya no esté disponible. Lo cual puede ser perjudicial en el caso de Single-layer al no realizar réplicas.
4. **Fuente no digitalizada:** o bien los pasamos a mano los datos, con escáner o técnicas especializadas de reconocimiento de caracteres. De nuevo, si solo se mantiene la arquitectura de un solo nivel, la digitalización de estos documentos se puede perder al no realizar réplicas.

1.4 Definition of Data Warehouse

Un Data Warehouse es una base de datos que sirve para **tomar decisiones**. Esta base de datos debería tener **4 características**:

- **Orientada a un tema:** se trata de poner juntos los datos de un mismo *tema* (*clientes, ventas, productos, etc.*) para mejorar el rendimiento (consultas más sencillas). No contiene los datos de todos los ámbitos de la empresa. Es lo contrario a orientado a funcionalidad.
- **Integrada:** tenemos diferentes tipos de datos (data sources) y los metemos en una única BD de manera que los datos se puedan cruzar.
- **Variante en el tiempo:** se refiere a la capacidad de una base de datos para mantener un registro histórico de los datos a lo largo del tiempo. En otras palabras, una base de datos variante en el tiempo permite almacenar y acceder a datos que cambian con el tiempo y mantener un seguimiento de las modificaciones y actualizaciones realizadas en esos datos.
- **No volátil:** los datos almacenados en la base de datos no se pierden ni se eliminan de manera accidental o automática. Los datos son persistentes y se mantienen en la base de datos hasta que se realice una acción específica para eliminarlos.

En este sentido, **Data Warehousing** es más un proceso que un producto. La filosofía de gestionar los datos. No es único sistema, sino es un conjunto que se tienen que interconectar para poder tomar decisiones.

1.5 Data Marts

Son pequeños almacenes de datos (Almacenes de datos departamentales/proyectos).

- Orientados a análisis.
- Normalmente, diseño multidimensional.
- Historial parcial, no hace falta almacenar datos muy antiguos.
- No necesita todas las fuentes de datos.

- No necesitan la granularidad más fina. Uso de datos mensuales, trimestrales, etc.
- Permiten una reducción del coste.

El error que podemos cometer con esto es que en lugar de tener un único proyecto generamos proyectos independientes (*Data Mars* completamente independientes). La manera correcta de hacerlo sería no sustituir el DW corporativo por los *Data Mars*, sino que **además de** tener el DW corporativo generar pequeños *Data Mars* para cada departamento/proyecto, ya que son más fáciles de gestionar de manera individual y tienen menos coste.

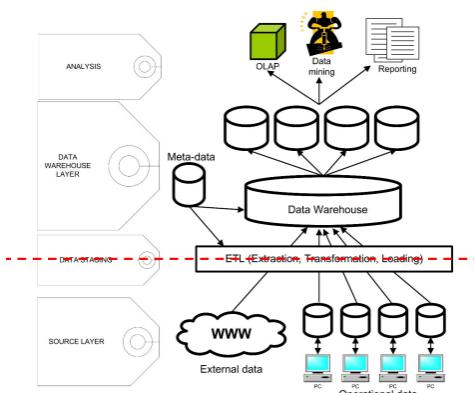
Por lo tanto lo que hacemos es crear un único repositorio donde cargamos todas las fuentes después de haberlas limpiado e integrado **únicamente una vez**. Cuando tenemos esta única fuente de conocimiento para la empresa, a partir de aquí generamos las diferentes **vistas** (*Data Mars*) para los departamentos/proyectos de análisis que tengamos.

Characteristics	Data warehouse	
	Departmental	Corporate
Subjects	Specific	Generic
Data sources	Few (some)	Many (all)
Size	Gigabytes	Terabytes
Development time	Months	Years
Data model	Multidimensional	Relational (file system)

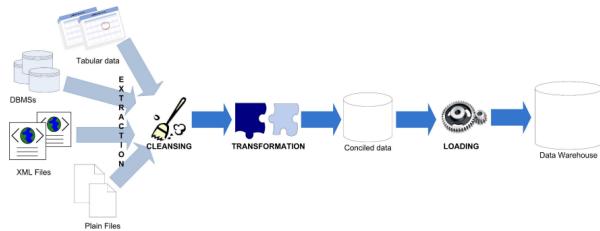
1.6 Two-layer architecture

Tenemos un **primer nivel** que son las **fuentes de datos operacionales y posibles datos externos**. A partir de aquí tendremos un **segundo nivel** que seria el **nivel decisional** donde tenemos nuestro **almacén de datos corporativos** con todos sus **Data Mars** y las herramientas de Análisis.

Añadimos un paso intermedio de **ETL** (Extract Transform Load) donde leemos los datos de estas fuentes operacionales (web, redes), **los limpiamos, los integramos** y los cargamos todos en este almacén de datos **orientado a temas, integrado, no volátil y variable con el tiempo (histórico)**, de manera que si estas fuentes de datos se pierden o cambian nosotros no perderemos estos datos.



El **ETL** tiene que **extraer** todos los datos de las diferentes fuentes, los va a **limpiar** (mirar si hay contradicciones entre las diferentes fuentes y cruzar unas con otros y ver si se pueden complementar), transformar (P.e normalización) y finalmente **conciliar**, ponerlos todos juntos y mirar que tengan sentido. Finalmente **cargaríamos** estos datos en nuestro almacén de datos, en nuestra fuente única de verdad de la empresa, a partir de donde definiríamos los Data Marts.

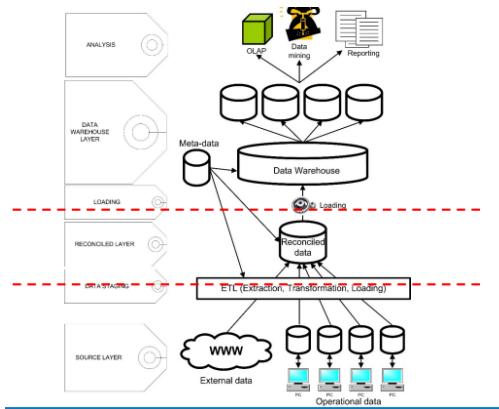


1.7 Three-layer architecture

En este caso tenemos 3 niveles. Mantenemos los dos niveles de antes (operacional y decisional) y introducimos un paso intermedio que son los **Datos Reconciliados**. Aquí, el ETL hace las tareas de antes pero para no molestar (reducir el coste) del DW no cargamos directamente los datos en este porque puede perjudicar la gestión y rendimiento de la BD, lo hacemos en dos pasos.

La carga del ETL la hacemos en una base de datos **temporal** (en el sentido que luego se va a borrar) y entonces una vez tengamos la **extracción, transformación y limpieza** de todas las fuentes de datos ahora en un único paso los volcaríamos en el DW todos de golpe y en un momento más adecuado (P.e por la noche o vacaciones).

Con este ganamos simplicidad de la arquitectura (dividir y vencer). Además estos datos reconciliados están disponibles mucho antes y el usuario puede consultarla también. Si nos esperamos a tener estos datos en el DW puede ser tarde para hacer según que tipo de cosas. Puede ser una ventaja competitiva para el negocio.



1.8 Metadata

Son datos más abstractos, datos que nos permiten **interpretar** otros datos. No hay que confundirlo con *derivados*, *sumarizados* o *agregados*, que son datos que se obtienen **a partir** de otros datos. Los metadatos son datos que **hablan de otros datos**. Algunos ejemplos de metadatos son: *fuentes de datos*, *documentación general*, *esquemas*, etc.

2 Multidimensional modeling

Una de las herramientas más utilizadas son las hojas de cálculo. Sirven muy bien para ciertas tareas pero tienen limitaciones.

- **No gestionan meta-datos:** Las filas y columnas se identifican con números y letras pero estos no tienen significado y su interpretación y operación puede resultar complicado. También su consulta.
- **Espacio limitado:** El número de filas y columnas es limitado y por lo tanto el número de celdas también. En la práctica es limitado.
- La posición de los datos limita las operaciones que podemos hacer.
- **Operaciones de agregación es limitada**, como p.e. querer agrupar clientes por distritos, el tiempo en meses y años, etc.

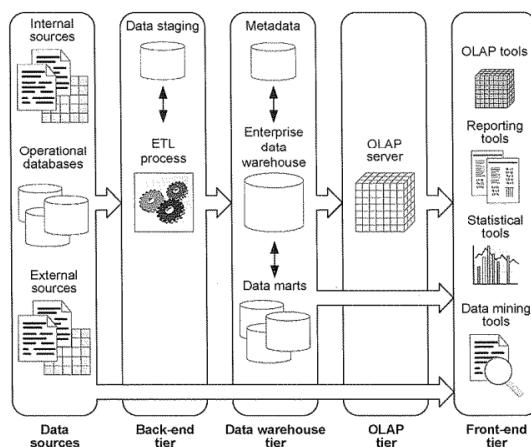
2.1 FASMI test

Cinco características que se tienen que cumplir las herramientas para el análisis de datos.

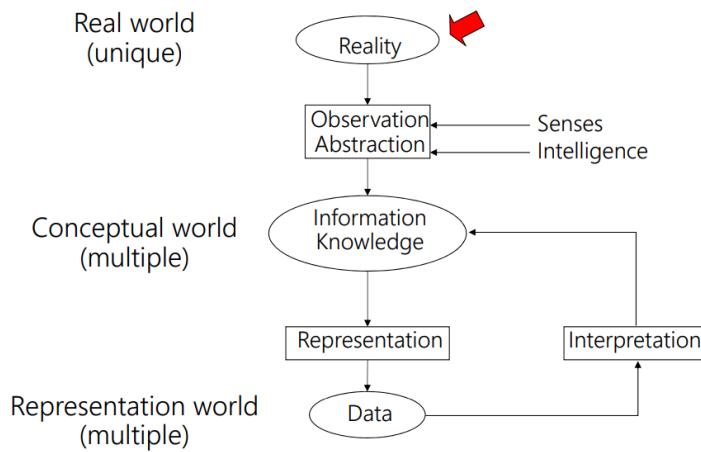
- (F) **Rápidas** independientemente del volumen de los datos.
- (A) Tienen que **permitir** hacer **análisis de los datos**
- (S) Se tiene que permitir interactuar de forma **concurrente** entre diferentes usuarios.
- (M) Multidimensional, las dimensiones no deberían estar limitadas.
- (I) Se debería permitir gestionar información y no solo datos. Para interpretar el contenido y su significado.

Las hojas de cálculo **solo cumplen** las **primeras dos características**. Permiten solo 3 dimensiones: filas, columnas y hojas. No permiten gestionar meta-datos y por lo tanto no permiten gestionar información.

Las bases de datos **operacionales** cumplen la compartición (concurrencia de diferentes usuarios) y la información (meta-datos mediante el uso de catálogos). La rapidez depende de las consultas. No están pensadas para hacer análisis, sino para consultas y modificación. Además no entienden el concepto de multidimensionalidad.



2.2 Real World



El mundo real es único en el modelo multidimensional, **solo hay un mundo que corresponde al mundo de nuestros datos** que queremos analizar. Pero se puede representar de varias maneras. En nuestro caso la representación sera en un **hipercubo**. Se pueden hacer operaciones con los hipercubos, como:

- **Slice:** Fijar un valor en una de las dimensiones. Deshacerse del resto de las dimensiones. Si se generaliza se pueden fijar varios valores en varias dimensiones y sería la operación *dice*.
- **Dice:** Se fijan varios valores en varias dimensiones. El resultado es una especie de dado.
- **Sort:** Aplicar una ordenación en una de las dimensiones. Por ejemplo poner en orden alfabético los atributos de esa dimensión.
- **Pivot:** Reordenar las dimensiones. Los datos del cubo no cambian, solo cambia como las visualizamos.
- **Roll-up:** Movernos en las jerarquías de agregación (*mapeos/correspondencias entre elementos de una misma dimensión p.e. Paris y Lyon los juntamos en una sola etiqueta llamada Francia y agrupamos sus valores*). Agrupación de los valores/datos dependiendo de un mapeo. Llevando esto al extremo podemos juntar los valores de toda una dimensión de manera que habrá una dimensión menos. Pérdida de detalle.
- **Drill-down:** Operación contraria de *Roll-up*. División de elementos en subelementos según jerarquías de agregación de una misma dimensión. Desglose de los datos. (*p.e Q1 se puede desglosar en Enero, Febrero y Marzo*).
- **Drill-across:** Operación binaria. Se necesitan dos cubos a la entrada de la operación. Join de cubos en lugar de tablas relacionales. Las dimensiones de los cubos tienen de coincidir para poder realizar la operación.
- **Union:** Se requiere que las dimensiones sean las mismas de los cubos de entrada. Pero los valores de las dimensiones no tienen porque coincidir. Equivalente a la unión de conjuntos.
- **Difference:** Equivalente a la diferencia de conjuntos. Quitar las celdas que coinciden en los cubos de entrada.

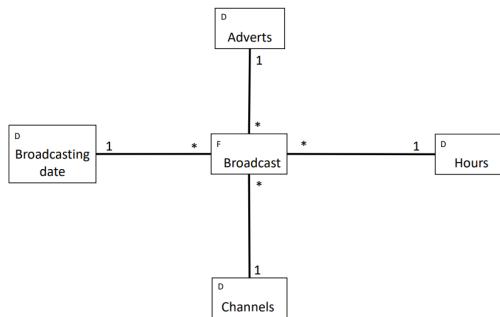
2.3 Conceptual World

Como se conceptualizan los hipercubos de datos? Hay **diferentes maneras de entender los datos conceptualizados**, porque se pueden interpretar de formas diferentes. Una manera de conceptualizar el mundo real es la notación **UML**.

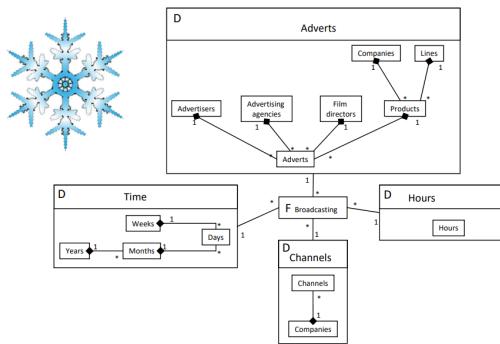
El modelo multidimensional de los cubos se centra en focalizar la información que nos interesa. De todas las interrelaciones, nos centramos en las que nos interesa y hacemos un esquema.

2.3.1 Types of schemas

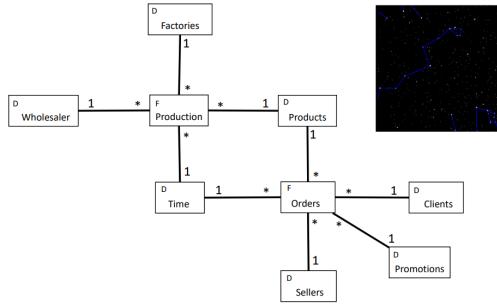
- **Star schema:** En el centro se coloca lo que se desea analizar y a los alrededores ponemos las diferentes dimensiones que tendrá el cubo para analizar el concepto central. Entre el concepto central y los extremos siempre hay una relación de uno a muchos $1 - - - *$. La ventaja es que selecciona de todo el dominio solo lo que nos interesa y de todos los tipos de relación solo nos fijamos en asociaciones de uno a muchos $1 - - - *$.



- **Snowflake:** Se ven el hecho central en medio y las dimensiones a los alrededor. En diferencia, es que además de las dimensiones se muestran las jerarquías de agragación. Es posible entonces realizar **Roll-up's**. Simplemente es dar más información al usuario.



- **Galaxy or Constellation:** En lugar de una sola estrella, se tendrían estrellas conectadas entre ellas mismas. Con dimensiones comunes, lo que facilita **Drill-across** de una estrella a otra.



2.4 Representation World

Se puede representar de formas diferentes pero siempre interpretables para obtener información para la toma de decisiones.

2.4.1 MOLAP: Multidimensional Matrix

(*Multi-dimensional Online Analytical Processing*)

La primera opción de representación es directamente agarrar el cubo y serializarlo. Estirarlo y ponerlo en fila. El disco no entiende de dimensiones, solo guarda 1 bit detrás del otro. Que se ajusta a la interpretación de los datos desde la memoria del disco. Se estira mediante hacer *slices*, hasta tener *slices* de dimensión asequible para poder almacenarlas de forma serial una detrás de la otra (2D).

La ventaja es que si se quiere recuperar todas los datos correspondientes a un mismo valor serán de fácil acceso porque están guardadas de forma serial (estarán almacenadas juntas dentro del disco). Pero dependiendo de la búsqueda los datos pueden no quedar a un solo acceso a disco, lo cual implicaría que las queries sean más costosas. Lo mismo pasa con las actualizaciones o inserciones que implicaría en algunas ocasiones regenerar todo el cubo. Desbalance entre queries muy rápidas y queries muy costosas. Si sabemos que tipos de consultas haremos o tenemos pocas dimensiones, puede resultar beneficioso.

2.4.2 ROLAP

(*Relational Online Analytical Process*)

La solución puede ser usar **herramientas relacionales**, donde guardar los datos de los cubos sería en un SGBD relacional y se necesitaría una capa de traducción que produzca la vista en forma de cubos. Funciona con lenguaje SQL y es fácil de obtener. El rendimiento de estas herramientas no es de lo más eficiente porque fueron concebidas para **OLTP** (*Online transactional process*) y lo que requerimos son **OLAP** (*Online Analytical process*). Cuando intentamos hacer esto usamos muchos *joins*, que son una operación muy costosa.

Star-join schema

En la traducción lo que haríamos es tener una tabla de hechos en el centro donde guardaríamos todas las celdas y las tablas de dimensión alrededor, una por cada dimensión. La tabla de hechos tiene *foreign keys* que apuntan a cada una de las dimensiones, estas llaves forman la *primary key* de la tabla de hechos. En las dimensiones tendríamos las jerarquías de agregación pero aplazadas.

Puede haber redundancia en los datos, por ejemplo en una tabla de *Time* los meses, trimestres y años se repiten mucho. Lo que se podría hacer es crear 3 tablas aparte y en

la de *Time* solo guardar el día, para que la información no se repita. Pero en este caso no es una buena idea, ya que la redundancia no es tanto como se puede pensar. Esto sucede porque la tabla de hechos siempre será de dimensiones mucho mayores que las tablas de dimensión y dominará el coste y el espacio, por lo tanto no es relevante por el volumen total que se tiene. Además el número de *joins* se incrementa. Lo cual también implica la simplificación del **Cube Query** (Patrón de consulta).

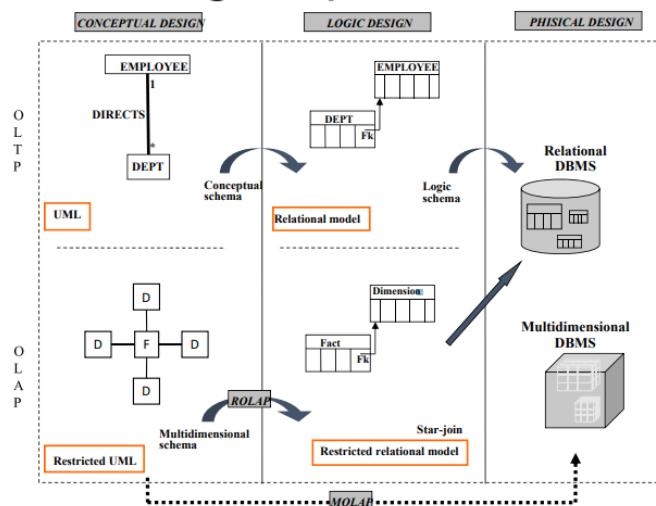
Cube-Query

```
SELECT d1.attr, ..., dn.attr, F(f.Measure1), ...
FROM Fact f, Dimension1 d1, ..., Dimensionn dn
WHERE f.key1 = d1.ID AND ... AND f.keyn = dn.ID AND <slice-dice condition>
GROUP BY d1.attr, ..., dn.attr
ORDER BY d1.attr, ..., dn.attr
```

```
SELECT h.name AS Hospital , t.month AS Month, AVG(cost)
FROM Admissions a, Hospitals h, Time t
WHERE a.HospitalId=h.Id AND a.TimeId=t.id AND t.year=2022
GROUP BY h.name, t.month
ORDER BY h.name, t.month
```

Los atributos del $\text{SELECT } d_i$ son los mismos que los atributos del ORDER BY y GROUP BY . Al saber que todas las consultas multidimensionales siguen este mismo patrón de consulta, esto facilita el trabajo del gestor relacional.

2.4.3 Comparison of Desing Steps: OLTP vs OLAP



En el caso de diseño OLTP creamos un esquema UML sin ningún tipo de restricción, cualquier tipo de relación entre las clases con cualquier tipo de multiplicidad, y esto lo traducimos al modelo relacional. Lo traducimos como ya sabemos: con tablas, llave primaria y foránea, etc. Finalmente esto se va a un SGBD relacional.

Cuando tenemos una tecnología OLAP seguimos un patrón de estrella con la tabla de hechos en medio y las tablas de dimensiones alrededor, solo se admiten relaciones $1 - - - *$. No podemos tener cualquier esquema UML sino sólo esquemas en formato estrella. No podemos traducirlo de cualquier manera sino con una tabla de hechos con una llave foránea para cada una de las dimensiones. Y todo éste se almacena en tablas relacionales y las consultas se realizan con SQL.

La alternativa es saltarnos el paso de traducción y directamente traducir del esquema de estrella, serializarlo, no guardarlo en SGBD relacional i guardarlo directamente en el disco con tecnología específica para serializar matrices y utilizando técnicas de indexación para recuperar fácilmente los datos.

Cuando tenemos pocas dimensiones o sabemos las consultas, serializar es normalmente mucho mejor. Cuando tenemos muchas dimensiones o no podemos saber las consultas que tendremos lo más seguro es apostar por un SGBD relacional. Lo que sucede normalmente es que ni estamos en un caso ni en el otro y tendremos que utilizar es un sistema híbrido.

2.4.4 HOLAP

Lo que se hace es mezclar las dos cosas, serialización de matices por un lado y sistemas relacionales por el otro.

- Los **cubos que son más densos** (con muchas celdas, sin huecos) los ponemos con una herramienta MOLAP porque serializar un cubo denso en mucho mejor porque no deja espacios. Cuando tenemos un **cubo más disperso** con espacios utilizaremos ROLAP que no deja vacíos, cuando no hay información no se guarda la fila.
- Los **datos atómicos** (datos que no se pueden dividir más) mejor guardarlos ROLAP ya que son más dispersos pero cuando comencemos agregar los cubos, estos son mas densos y sale mas a cuenta MOLAP.
- Si tenemos **datos que son accedidos muy frecuentemente** y sabemos las consultas más utilizadas mejor serializar de forma adiente para recuperarlas de forma rápida. Las que no tenemos claro cuándo y como se accederán las ponemos con una herramienta ROLAP.

3 Advanced Multidimensional Design

3.1 Algebraic operations

Conjunto de operaciones algebraicas y como pueden operar en un cubo de datos. Como se transforma la consulta SQL. Hay diversas operaciones:

- **Selection (<cube>, <predicate on dimensions>)**: Nos permite hacer *slices* en *dice* dada una condición en una dimensión.
- **Projection (<cube>, <measures left>)**: -Nos permite eliminar medidas del cubo.
- **Roll-up (<cube>, <destination level>[, <aggregation function>])**: Subir jerarquías de agregación, cuando subimos, como estamos agrupando los datos tenemos que indicar que función (como es opcional, por defecto es la SUM).
- **Drill-Down (<cube>, <destination level>)**: Bajar la jerarquía de agregación.
- **Drill-Across (<cube>, <new fact>[, <aggregation function>])**: Nos permite hacer *joins* entre cubos (como es opcional la función de agregación, por defecto es la SUM).
- **ChangeBase (<cube>, <new base>)**: Nos permite reordenar las dimensiones o los datos dentro de las dimensiones. Hay que indicar con qué dimensiones nos quedamos y el orden de estas. Cuando se usa para eliminar una dimensión esta debe ser una constante.

Mirar [video](#) para ejemplo.

3.2 Advanced Design

Vamos a ver técnicas que nos ayudan a reflectar la realidad y algunos casos especiales que tráctaremos.

1. **Factless Facts**: El primero es el caso en que la **tabla de hechos no tiene ningún atributo**, no tiene medidas. Aun así podemos seguir **contando** hechos. Hay casos donde interesa **registrar algún evento** como *p.e la asistencia de los estudiantes en las clases. Entonces para cada estudiante, para cada clase y franja horaria pondríamos una fila en la tabla de hechos y dejaríamos constancia de esto. Esto nos permitiría contar el número de asistencias a clase.*

Otra situación donde nos encontramos esto le decimos **coverage** (cobertura). Es cuando queremos dejar constancia de cosas que no están ligadas a ningún evento. *P.e las promociones. Si ponemos algún producto en promoción y no hay ninguna venta esta promoción no quedaría registrada en nuestra BD. Entonces para cada tienda, tiempo, producto, etc. dejamos constancia de si esta promoción se ha dado en el algún momento independientemente de si han habido ventas o no. Esto nos permitiría como en el caso de antes contar el número de promociones que había en un cierto instante de tiempo.*

Esto aparece solo en el nivel mas bajo de granularidad, porque en el momento que contamos generamos una medida y podemos seguir contándola, hacer el min/max... El nivel más bajo que guardaríamos en nuestro *datawarehouse* sería sin ninguna medida.

2. **Degenerated Dimensions**: Sigue no cuando el hecho no tiene medidas sino cuando la dimensión no tiene atributos, entonces hablamos de dimensiones degeneradas. Sirve para **dejar constancia** y permitir un **mejor análisis**. En este caso no ponemos llave foránea ya que no sirve de nada porque la dimensión a la que

hace referencia no tiene atributos (no hay dimension a la que apuntar realmente por eso). La dejamos parte de la llave primaria de la tabla de hechos.

3. **Junk Dimensions:** Caso contrario al anterior, lo que tenemos es muchos atributos dimensionales booleanos o de cierto número pequeño de valores. Para guardarlos, la primera opción sería hacer **una dimensión para cada una de ellos** con una llave foránea a cada una de las dimensiones. No es una buena opción ya que estas no tienen atributos y estariamos malgastando espacio y tiempo de hacer *joins*. Otra opción es ponerlos en la llave primaria pero no poner la llave foránea, sin embargo, esto hace que la llave primaria crezca sin sentido. La tercera y mejor opción sería crear una tabla para cada combinación de los atributos en la llave primaria tenemos llave foránea a esa tabla que tiene un identificador que nosotros creamos. De esta manera la tabla de hechos no crece tanto. Esta solución tiene ventajas ya que nos ahorra tiempo en la tabla de hechos y nos permite analizar las combinaciones de los atributos puestos en la tabla y mirar si hay correlación en los elementos de la tabla.
4. **Too large dimensions:** Otro caso que puede suceder es que algunas dimensiones que en general son pequeñas comparadas con la tabla de hechos pueden estallar. *P.e en la tabla de tiempo si ponemos segundos, minutos, horas, durante años. La solución seria todo lo que hace referencia al tiempo ponerlo en una dimensión y todo lo de la fecha en otra dimensión.* Las consultas serán un poco mas difíciles por la combinación de JOIN. La ventaja es que podemos analizar mas fácilmente el tiempo del día en que se hacen ventas porque solo tenemos que consultar una sola tabla.
5. **Slowly Changing Dimensions:** Otro problema que nos podemos encontrar es que aunque normalmente las dimensiones no cambian, pueden acabar cambiando por dos razones. La primera porque la realidad puede cambiar (*p.e una ciudad obtiene la independencia de su país*) y la segunda son errores humanos (*p.e nos equivocamos de Barcelona*). El problema que tenemos es como dejar constancia de estos cambios. Hay 3 opciones:
 - **Sobrescribir el valor:** opción más sencilla pero perdemos constancia del valor anterior.
 - **Añadir una nueva columna** donde dejamos constancia del valor anterior. Si el valor no ha cambiado le ponemos NULL y si ha cambiado le ponemos el valor anterior. Solo permite reflectar un cambio, a no ser que añadamos muchas columnas por cada cambio que se realiza.
 - **Añadir columna de tiempo** que nos dice para cada fila hasta que momento ese valor es válido. Es la opción más complicada pero a la vez la más genérica. En este caso el tiempo también forma parte de la *primary key* porque sino aparecerían repetidos (puede haber dos instancias de la misma primary key pero no en el mismo instante de tiempo).
6. **Aggregation hierarchies:** Tendemos a pensar que las jerarquías de agregación son lineales, pero no es verdad, en general pueden tener cualquier topología. Se tratan de un grafo donde lo único que se tiene que cumplir es que haya un único nivel arriba (ALL) y otro nivel que está abajo de todo que es donde apunta la tabla de hechos. En medio puede ser lineal pero no tiene porque serlo. Esto no afecta a la implementación. Podemos explicitarlo en el esquema *snowflake* o de manera implícita en el *star schema*. A nivel de implementación lo único que pasará es que tendremos mas atributos en la tabla de dimensiones.
7. **Conformed hierarchies/dimensions:** Cuando tenemos diferentes dimensiones compartidas en diferentes esquemas de estrella (esquemas de galaxia). Puede ser que estas estrellas vengan de diferentes fuentes pero deberíamos de conformarlas. Si tenemos que hacer *joins* entre ellas y lo que no puede ser es que las tablas

sean diferentes. Esta información que vienen de diferentes fuentes la tenemos que homogeneizar (tenerla de la misma forma) para que todas tablas de hechos puedan apuntar a la misma dimensión.

Lo que hay que hacer es crear una tabla donde en las filas tenemos las diferentes tablas de hechos y en las columnas tenemos las diferentes tablas de dimensión. Haciendo esto podemos ver las dimensiones que comparten y homogeneizar estas.

3.3 Aggregation Problems

Vamos a ver los problemas de agregaciones del modelo multidimensional y las situaciones que pueden surgir. Esto es importante porque las jerarquías de agregación y las operaciones *roll-up* son las operaciones más importantes de los cubos de datos.

- Lo primero que debemos mirar es que las categorías deben de ser **disjuntas**. Un dato no puede pertenecer a más de un valor de la misma categoría para que se pueda realizar la agregación.
 - En el caso de disyunciones (donde las categorías se solapan) se crea una *puente* intermedia donde guardaríamos el peso de cada relación. *P.e si un alumno pertenece a dos asignaturas se le asignaría un peso de 1/2 a cada una para que a la hora de sumar solo cuente como 1.*
- Los datos deben estar **completos**, si hacemos la agregación debe ser el total real. Lo que estamos sumando tiene que corresponder al total.
 - Si la jerarquía de agregación es **incompleta** lo que deberíamos hacer es añadir fantasmas (valores ficticios) que sirvan para agregar las consultas¹.
- Tenemos que mirar las 3 características sean **compatibles**: el **tipo de dimensión** (temporal o no), **tipo de medida** (acumulativa, estado o valor por unidad) y el **tipo de función de agregación** que estamos utilizando (*min, max, avg, sum*).
 - Se trata de una relación ternaria, si las miramos por parejas no tenemos suficiente información para saber si lo que hacemos es correcto.

	Cumulative	State	Value per unit
min	No problem	No problem	No problem
max	No problem	No problem	No problem
sum	No problem	Non-temporal	Never
avg	No problem	No problem	No problem

¹El nivel más bajo normalmente corresponde al que tiene más instancias

4 Extract, Transform and Load

Extraer datos desde de una o múltiples fuentes, transformarlas según las necesidades y cargarlas a otro repositorio de datos. Puede ser por varios motivos:

- Simplemente **para guardar los datos**. No es lo mismo que un *backup* porque un *backup* se tiene que restaurar pues es una captura instantánea de los datos y no es habitual acceder ni transformar los datos.
- Por el **uso de herramientas específicas que necesitan una cierta estructura** específica de los datos (e.g aplicaciones para *machine learning*) y se necesitan transformar para el sitio en donde se usarán.
- La **integración de datos**, tenemos múltiples fuentes y se necesitan usarlas todas juntas.
- **Para asegurar que no se pierden/alteran los datos**. Pasa en entornos web, donde se cambia sin avisar o sin pedirnos permiso. Lo mejor es extraerlos y ponerlos en donde si tenemos un control.
- **Eliminar errores de las fuentes de datos y arreglarlos** que sabemos que existen en todas las fuentes de datos. Aplicar algoritmos de limpieza.
- **Corregir/Imputar** los valores faltantes. Como en la mayoría de casos no tenemos control para modificar las fuentes de datos, copiamos los datos en nuestro repositorio y allí las modificamos.

Todo esto permitido hasta un cierto punto, pues se tienen que respetar **aspectos legales y éticos que hay sobre los datos**. Primero nos tenemos que preguntar de quien son los datos y si tenemos permiso para hacer lo que queremos hacer. **Se les ha informado al propietario de los datos para poder hacerlo?**

Especialmente crítico cuando se trata de **datos personales**. En el caso de que se nos de permiso, debemos garantizar la confidencialidad tanto de los datos como del uso que se le dará al resultado de nuestro análisis.

4.1 Definition

4.1.1 Extraction

Tenemos múltiples tipos de datos que además son heterogéneos. Hemos de integrarlos. Dependiendo de las **características temporales** que tengan los datos se nos será más fácil o difícil extraer los datos:

- **Transitorio:** El caso más difícil, es cuando la base de datos no tiene ninguna característica temporal, no guarda ningún valor antiguo. Si se produce un cambio entre 2 extracciones, el cambio entre valores se perderá.
- **Semi-periódico:** guardan 1 de los cambios (siempre guardan el valor anterior). Mientras que no hayan dos cambios o más entre extracciones, estos valores no se perderán.
- **Temporal:** que guarde absolutamente todos los cambios que se han hecho. No hay problema para hacer la extracción, solo se pide todos los cambios desde la última extracción.

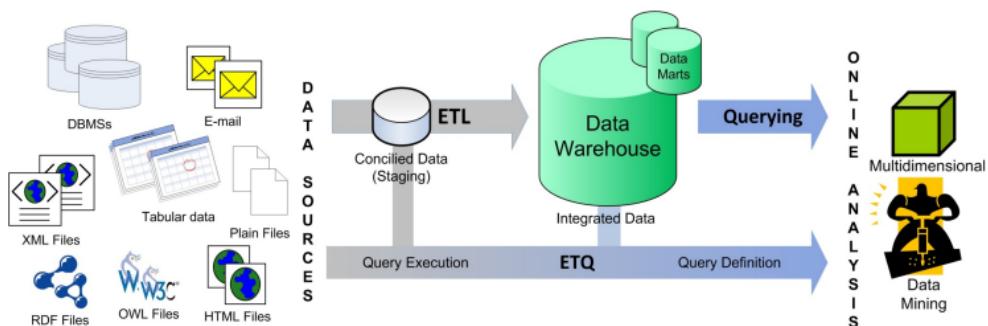
4.1.2 Transformation

- **Cambiar esquema:** por temas de integración, temas de estructura de datos para uso de herramientas de análisis, etc.
- **Convertir el conjunto de caracteres:** Pasa cuando tenemos distintos sistemas operativos o diferentes SGDB's y se utilizan conjuntos de caracteres diferentes. Caracteres extraños (e.g acentos o la ñ en castellano) que pueden salir raros.

- Mejorar la calidad de datos: Limpieza, imputación, completar fuentes, etc.

4.1.3 Load

- On-line
- Off-line: hacemos fuera a los usuarios del sistema para cargar los datos (*update window*). Durante la ventana de actualización, los usuarios no pueden trabajar con el sistema (el sistema está *offline*). Mientras está fuera de línea, cargamos los datos al DW y cuando acabamos lo ponemos a trabajar. Usualmente en la noche/fin de semana.
- Durante la carga se **desactivan/borran los índices** ya que insertar de uno en uno es mas costoso que no insertar todos los datos de golpe dentro del índice. A veces desactivamos el índice, esperamos que acaben las inserciones y actualizamos el índice con todas las inserciones que se hayan hecho o a veces borramos el índice y lo recreamos de nuevo (si el algoritmo de inserción es el mismo, no tiene mucho sentido recrear el índice). Solo en carga off-line, en online no podemos borrar los índices porque sino los usuarios no podrían trabajar.



En la imagen podemos observar una estructura más de alto nivel de como funciona el ETL. En la entrada tenemos diferentes tipos de fuentes de datos. Lo más importante aquí es que pasamos el **ETL a una área de trabajo (staging area)** donde de forma **temporal** podemos **materializar resultados parciales de estas transformaciones**. Esto nos hace más eficiente estas transformaciones y también puede servir para, si una cosa falla, no tener que volver hasta el principio. Es una práctica habitual tener algún tipo de almacenaje temporal para el ETL.

Una vez acabadas estas transformaciones **cargaremos los datos en nuestro almacén de datos** (DW) y desde este almacén de datos corporativo crearíamos nuestro Data Mars. Una vez hecho esto tenemos herramientas multidimensionales, Data Mining y Machine Learning que accederían a este DW o a los Data Mars y harían estos análisis. Esto sería el ETL tradicional.

Cada vez tenemos más prisa y urgencia por tener las cosas, la creación del DW a veces no nos conviene porque enlentece la fase de consulta (e.g mientras cargamos y no cargamos alomejor ha pasado un día). La alternativa de hoy en día es ejecutar consultas contra las fuentes y contra la área temporal del ETL (staging). Una vez tenemos estos datos extraídos de las fuentes hacemos una transformación mínima (normalmente sin mejora de calidad porque cuesta mucho tiempo) y se la pasamos a los usuarios. En vez de hacer *Load* de los datos hacemos directamente *Query*, es lo que se conoce como ETQ.

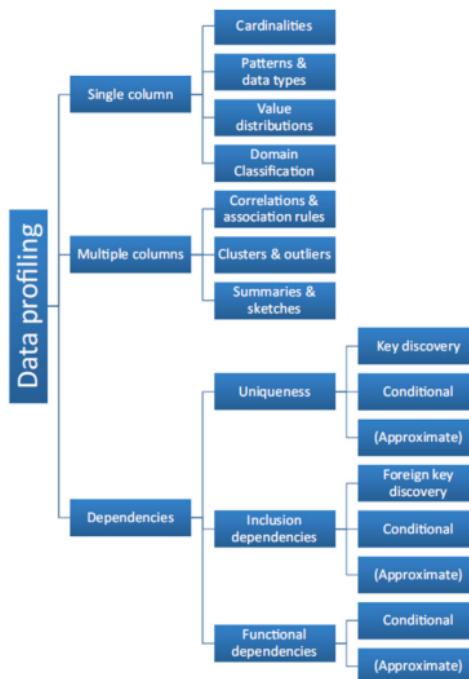
Otra alternativa es ELT (impulsada por vendedores de SGBD). No se hace la transformación en cualquier lenguaje/herramienta, sino que directamente se cargan los datos a la base de datos y la base de datos es capaz de hacer las transformaciones dentro del SGBD. Fusionar el *staging area* con el DW.

4.2 ETL Steps

No se puede poner en el DW todos los datos del mundo. **Definir los objetivos de negocio y el análisis** (target MD schema donde queremos cargar los datos). Lo más importante es que sean **datos relevantes y que no sean redundantes** ni de baja calidad, en términos de completeness, precisión, consistencia (cumples las restricciones de integridad), vigencia. **Garbage in - Garbage out**.

Para saber esto se necesitan entender los datos (**data profiling**). Por temas de calidad, ver las características y ver si encajan con lo que queremos hacer (cuestión relativa a los objetivos).

- **Mirar los datos de uno en una:** Si siguen un patrón, que distribución de valores tienen y posible clasificación dependiendo de su dominio.
- **Múltiples columnas a la vez:** buscar correlación o reglas de asociación, clusters o outliers y crear resúmenes (sketches) de estos datos.
- **Dependencias entre los datos:** ver si realmente tienen repetidos (considerar claves primarias), buscar inclusiones dependientes (claves foráneas) o dependencias funcionales (un valor determina el valor del otro).

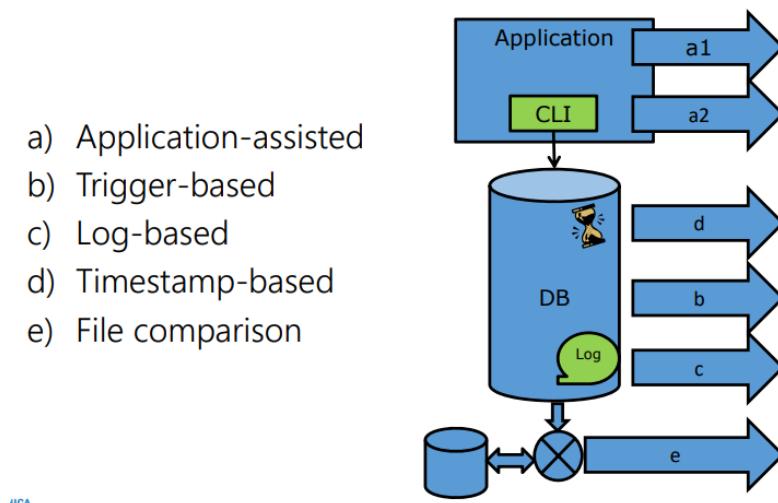


4.2.1 Data extraction mechanisms

Tenemos que ver como extraer los datos.

- **Las interceptamos en la propia aplicación que las está generando.**
 - Modificar el código de la aplicación para que a la vez que se hace la inserción a la base de datos, nos la envié a nosotros en algún sitio que digamos.
 - Modificamos el driver (*call level interface*) de manera que cuando desde la aplicación se escriba para hacer una inserción a la base de datos, automáticamente el driver replique este dato a nosotros. La modificación del driver puede ser más complicada al inicio pero a largo plazo es mejor. No se debe conocer la aplicación, ni sufrir por modificaciones de la aplicación.
- **Nos esperamos que la aplicación la cargue a la base de datos y las cogemos de ahí.**
 - Mediante **triggers** (mecanismos que cuando se hace cualquier modificación en la BD se hace una acción) para que nos envíen los datos.
 - Podemos mirar los mecanismos del log. El log es el sistema para recuperarse si hay una falla (energética, etc). El log tiene constancia de los cambios que se han hecho en la base de datos. Si es software abierto, si es software propietario el formato del log no se conoce y no se puede hacer.
 - Consultas directas contra la base de datos. Si la BD es temporal, permite hacer consultas contra el histórico. Entonces pedimos todos los cambios que han habido desde la última extracción.
 - Extraer todos los datos de la BD y compararlos con la extracción previa que se haya hecho y ver las modificaciones desde entonces.

- a) Application-assisted
- b) Trigger-based
- c) Log-based
- d) Timestamp-based
- e) File comparison



4.2.2 Kinds of transformation tasks

La primera sería la selección de los datos. Se tiene que mirar que sean relevantes, etc.

Cleaning

En general mejorar la calidad de los datos. Primero generar los perfiles para entender lo que tienen y lo que no.

- **Algunos atributos que seguramente tengan información compuesta.** e.g una columna con la dirección puede tener el nombre de la calle, el zip, etc. que a lo mejor es más efectivo analizar por separado.
- **Estandarización:** de valores numéricos pero también de str.
- **Mejora de la calidad:**
 - *Completeness:*
 - * **Introducir valores manualmente:** normalmente no es buena idea, es demasiado farragoso.
 - * **Poner valor por defecto:** tampoco es buena idea, no da buen resultado en general.
 - * **Average/mediana/moda**
 - * **Average/mediana/moda por clase**
 - * **Aproximación de TEOI:** poner el valor que aporta la mayor información.
 - * **Tablas de lookup** donde tenemos correspondencias para cada valor.
 - *Correctness:*
 - * **Diccionarios (tablas de lookup)** para corregir valores
 - * **Detección de outliers:** detectar outliers sin borrarlos (pueden ser importantes), solo identificarlos.
 - *Analizar las restricciones de integridad (business rules).*

Size reduction

Si pensamos en los datos estructurados en formas de tabla, solo se puede reducir en número de filas o columnas.

- *Por filas (length):*
 - **Agregación:** groupby y nos quedamos con el promedio, mediana, min, max, etc.
 - **Representativo:** clustering y nos quedamos con algún representante (el centro normalmente).
 - **Muestreo**
- *Por columnas (atributos):*
 - **Correlación:** la información ya nos la da otra columna.
 - **Análisis de significación:** para ver si realmente nos da información relevante.
 - **Ganancia de clasificación**

Preparation

Puede pasar que algunos algoritmos tengan algunos requisitos específicos (solo valores numéricos, etc.).

- **Categórico a numérico**
- **Diferentes métodos de discretización,** numérico a categórico
- **Normalizar**
- **Conversión de los datos a metadatos (Onehot encoding):** para algoritmos que no permiten datos multivaluados (*listas*).

- **Derivación de información:** e.g un algoritmo con la data de nacimiento trabajará peor que con la edad (derivar la columna)
- **Enriquecimiento:** Haciendo `join` con otras fuentes de datos, mientras sea relevante.

4.3 ETL process design

El diseño funciona parecido al que hacemos cuando se diseña una BD, es decir, tenemos primero un diseño **conceptual, lógico y físico**.

- **Diseño conceptual:**
 - Puede realizarse en múltiples aplicaciones como UML o incluso lenguajes específicos para diseñar ETL.
 - Con el propósito de mejorar la comprensión y tener la posibilidad de compartirlo.
 - Incluso una posibilidad de automatizar la traducción al diseño lógico si escogemos la herramienta adecuada.
- **Diseño lógico:**
 - Descripción detallada del workflow, las dependencias, el esquema y los planes de restauración.
 - Representado por un grafo dirigido acíclico donde los vértices son las fuentes de datos, operaciones o "targets" y las relaciones indican las dependencias/flujos de datos que hay de un nodo a otro. (Talend)
 - Se muestran las transformaciones que sufren los datos.
- **Diseño físico:** generado automáticamente a partir del diseño lógico.

4.3.1 ETL tools GUI

Herramientas gráficas (Talend). Recomendado para proyectos grandes, procesamiento relativamente sofisticado y/o cuando no tenemos mucha habilidad de programación. Además de eso proporciona:

- **Un repositorio de metadatos integrados.** Deja constancia de todo lo que se tenga (fuentes de datos, transformaciones, cargas).
- **Conversiones de tipos de datos automática y comprobación de errores.**
- **Trazar/visualizar de donde vienen los datos y de que dependen las cosas cuando se cargan los ficheros.**

4.3.2 Hand-coded ETL

Posibilidad de sustituir la automatización. Recomendable cuando tenemos el conocimiento, hay rutinas ya implementadas o cuando las herramientas ya preestablecidas no hacen exactamente lo que queremos que hagan.

Conjuntamente con esto, si queremos hacer un proceso similar a *Map-Reduce* (librerías de Spark) se necesitarían hacer a mano y eso nos facilitaría el uso de datos sin esquema (e.g imágenes, texto en lenguaje natural). Se preprocesarían estas fuentes con el *Map-Reduce* y a partir de aquí se extraerían una serie de características que se cargarían a un SGBD y ya se podría continuar con todo el procesamiento que se desea.

4.3.3 ETL process quality

En cualquiera de las dos alternativas, se tiene que mantener unos estándares de calidad.

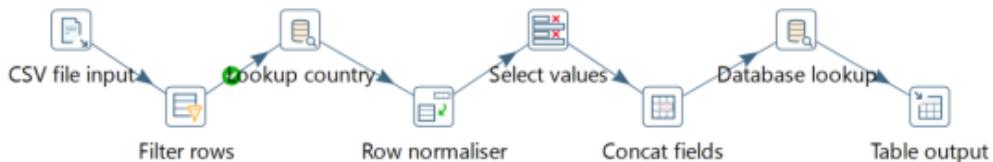
- **Rendimiento:** el más importante. Se ha de ejecutar de la manera mas rápida y eficientemente posible, pensando en la escalabilidad. Con recursos razonables dentro del presupuesto.
- **Confianza:** de solucionar los posibles errores en términos de robustez. Gestión de errores, tolerancia a fallos y recuperabilidad.
- **Testabilidad:** tenemos de ser capaces de testar el código incluso tras hacer cambios. Comprobar que se mantiene la eficiencia. También tienen que ser traceables, saber de donde vienen.
- **Mantenibilidad:** muy importante si se piensa en el futuro. El ETL se ha de ejecutar de manera recurrente a lo largo del tiempo, habrá cambios en las fuentes, etc. y se tiene que mantener/cambiar. Entonces depende de como se defina el coste de mantenimiento en el presente, afectará en un futuro.
 - Se tiene que intentar hacer el código/ETL más comprensible. (etiquetar, anotaciones, comentarios, etc.).
 - Mantenibilidad difícilmente cuantificable. Aunque existen algunas métricas como (#operaciones, #fuentes) pero son bastante evidentes y no se puede hacer mucho.
 - Se puede hacer Modularidad/Encapsulación: definición de métodos, funciones significativos con comentarios que pueden ser reutilizables de la manera mas conveniente para ayudar a la mantenibilidad.

4.4 Architectual setting

Distinción entre **data flow** (flujo de datos) y **control flow** (flujo de control).

4.4.1 Data flow

También conocido como **transformación**, lo que hace es transformar los datos. El orden de ejecución no se puede saber a menos de que haya precedencias claras en el grafo. Las aristas de este grafo dirigido lo que muestran es como los datos van pasando de una transformación a la otra.



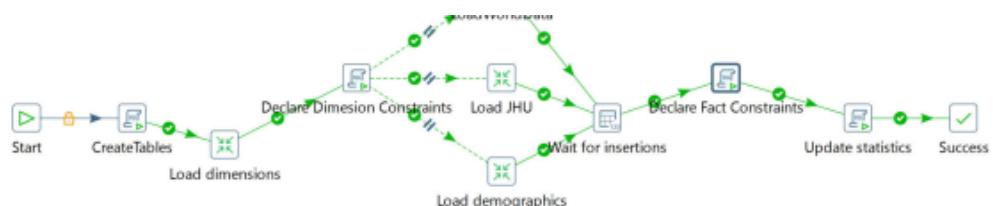
- **Fuente (Source):** Es el punto de origen de los datos, donde se inicia el flujo de datos. Puede ser una base de datos, un archivo, un sensor, una API, u otras fuentes de datos.
- **Transformación (Transformation):** Son las operaciones que se aplican a los datos a medida que se mueven a través del flujo. Las transformaciones pueden incluir filtrado, limpieza, agregación, cálculos y cualquier cambio en la estructura o el formato de los datos.
- **Ruta (Path):** Es la dirección en la que fluyen los datos desde la fuente a través de las transformaciones hasta llegar al destino.

- Destino (Destination): Es el punto final del Data Flow, donde se almacenan los datos procesados o se utilizan para un propósito específico. Puede ser una base de datos de destino, un almacén de datos, una aplicación, un informe, entre otros.

4.4.2 Control flow

Si queremos forzar un orden de ejecución, también se llaman **Jobs**. Las aristas de este grafo ya no indican paso de datos entre tareas, sino que precedencias entre tareas. Comenzamos con un evento inicial, tenemos un evento final y en medio tenemos diferentes transformaciones complejas. Las aristas indican precedencias. Puede ser secuenciales o paralelas.

La dependencia es muy importante, e.g. se deben cargar las tablas de dimensión antes que las tablas de hecho porque sino habría errores de `foreign key`.



Distinción importante entre las aristas de ambos grafos. Las del **data flow** muestran el paso de datos entre una tarea y otra. Mientras que las aristas del **data control** muestran precedencia entre tareas. El flujo de control lo único que indica es precedencia, que se hace antes de que, pero no indica flujo de datos, no se pasan datos entre ellos, simplemente un planificador.

4.4.3 Staging area

Es un sistema de almacenamiento usado para mejorar el funcionamiento o el rendimiento del ETL. Pueden estar guardadas los datos aquí en ficheros planos, *XML*, tablas relacionales o en cualquier otro formato.

Lo importante es que facilita la ejecución del ETL. Puede hacer que vaya más rápido, hacerlo recuperable, puede hacer *backups* (por si alguna cosa no interesa repetir la ejecución) o bien puede servir para hacer auditoría (dejar constancia de las transformaciones que se hacen y las correspondencias que hay entre unos datos y otros).

4.4.4 Metadata management

Muchas veces los metadatos se nos permiten extraer de forma automática (e.g. de las fuentes de datos o de la **Staging area**), en qué formato están, qué tipo de datos son, etc. Lo mismo para el DW. También metadatos del proceso de ejecución como cuantas filas tenemos. Incluso alguna herramienta para la definición de las reglas de negocio.

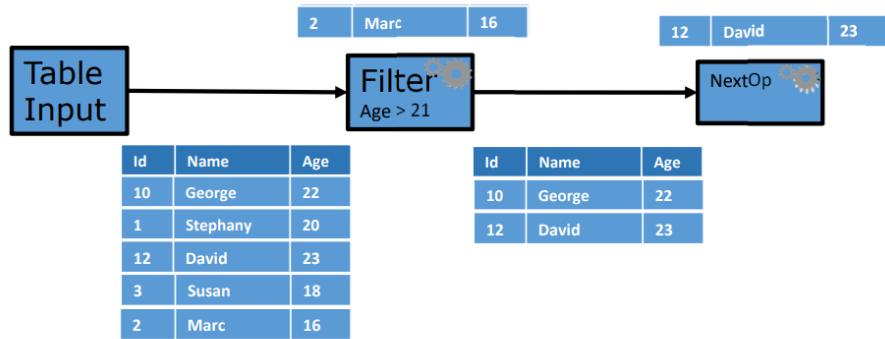
4.5 ETL operations

Operation Level	Operation Type	Pentaho PDI	Talend Data Integration	SSIS	Oracle Warehouse Builder
Field	Field Value Alteration	Add constant Formula Number ranges Add sequence Calculator Add a checksum	tMap tConvertType tReplaceList	Character Map Derived Column Copy Column Data Conversion	Constant Operator Expression Operator Data Generator Transformation Mapping Sequence
Dataset	Duplicate Removal	Unique Rows Unique Rows (HashSet)	tUniqRow	Fuzzy Grouping	Deduplicator
	Sort	Sort Rows	tSortRow	Sort	Sorter
	Sampling	Reservoir Sampling Sample Rows	tSampleRow	Percentage Sampling Row Sampling	
	Aggregation	Group by Memory Group by	tAggregateRow tAggregateSortedRow	Aggregate	Aggregator
	Dataset Copy		tReplicate	Multicast	
Row	Duplicate Row	Clone Row	tRowGenerator		
	Filter	Filter Rows Data Validator	tFilterRow tMap tSchemaComplianceCheck	Conditional Split	Filter
	Join	Merge Join Stream Lookup Database lookup Merge Rows Multiway Merge Join Fuzzy Match	tJoin tFuzzyMatch	Merge Join Fuzzy Lookup	Joiner Key Lookup Operator
	Router	Switch/Case	tMap	Conditional Split	Splitter
	Set Operation - Intersect	Merge Rows (diff)	tMap	Merge Join	Set Operation
	Set Operation - Difference	Merge Rows (diff)	tMap		Set Operation
	Set Operation - Union	Sorted MergeAppend streams	tUnite	Merge Union All	Set Operation

Operation Level	Operation Type	Pentaho PDI	Talend Data Integration	SSIS	Oracle Warehouse Builder
Schema	Field Addition	Set field value Set field value to a constant String operations Strings cut Replace in string Formula Split Fields Concat Fields Add value fields changing sequence Sample rows	tMap tExtractRegexFields tAddCRCRow	Derived Column Character Map Row Count Audit Transformation	Constant Operator Expression Operator Data Generator Mapping Input/Output parameter
	Datatype Conversion	Select Values	tConvertType	Data Conversion	Anydata Cast Operator
	Field Renaming	Select Values	tMap	Derived Column	
	Projection	Select Values	tFilterColumns		
Table	Pivoting	Row Denormalizer	tDenormalize tDenormalizeSortedRow	Pivot	Unpivot
	Unpivoting	Row Normalize Split field to rows	tNormalize tSplitRow	Unpivot	Pivot
Value	Single Value Alteration	If field value is null Null if Modified Java Script Value SQL Execute	tMap tReplace	Derived Column	Constant Operator Expression Operator Match-Merge Operator Mapping Input/Output parameter
Source Operation	Extraction	CSV file input Microsoft Excel Input Table input Text file input XML Input	tFileInputDelimited tDBInput tFileInputExcel	ADO .NET / DataReader Source Excel Source Flat File Source OLE DB Source XML Source	Table Operator Flat File Operator Dimension Operator Cube Operator
Target Operation	Loading	Text file output Microsoft Excel Output Table output Text file output XML Output	tFileOutput tDelimited tDBOutput tFileOutputExcel	Dimension Processing Excel Destination Flat File Destination OLE DB Destination SQL Server Destination	Table Operator Flat File Operator Dimension Operator Cube Operator

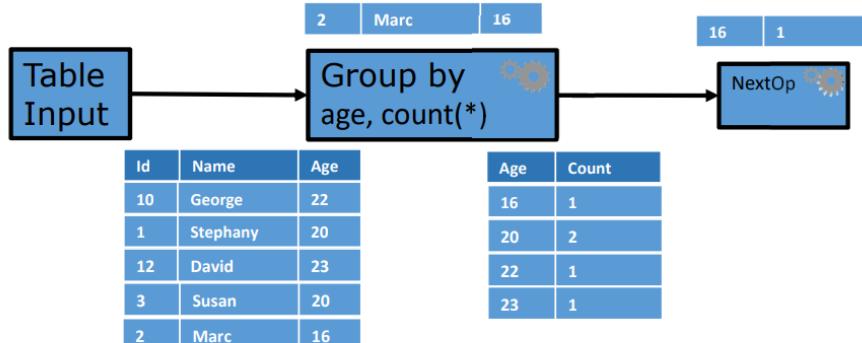
4.5.1 Non-Blocking Example

El filtro cogería fila por fila y comprobaría la condición del filtro. Mientras una fila este en estado de comprobación en el filtro, la fila anterior que pasó por el filtro ya puede haber pasado a la siguiente operación para procesarla. Las dos operaciones adyacentes se están ejecutando en paralelo.



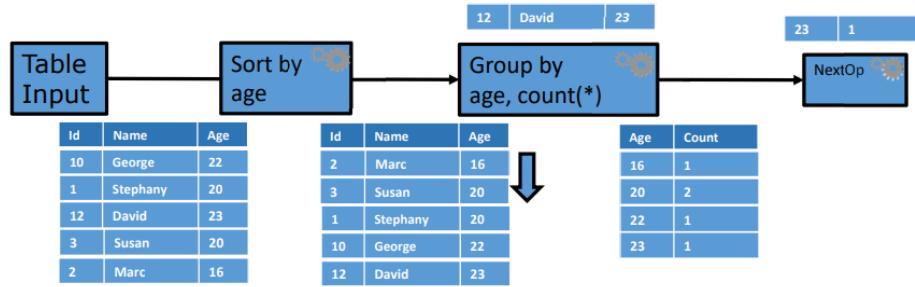
4.5.2 Blocking Example

Group by. No ha generado nada a la salida hasta que no se acaben de preprocesar todas las filas, porque no puede saber si para una edad determinada cuantas de esta habrá en total hasta que no se acabe de leer todas las entradas. Solo cuando ha terminado de leer la última fila, la próxima operación puede comenzar a procesar.



4.5.3 Blocking optimized Example

Una manera de optimizar este caso es (para el ejemplo dado) es realizar una operación de `sort by` para ordenar los datos de manera que se sabe cuando se acaban las filas con el mismo valor para el `group by`. Ahora la operación de bloqueo es el `sort by`.

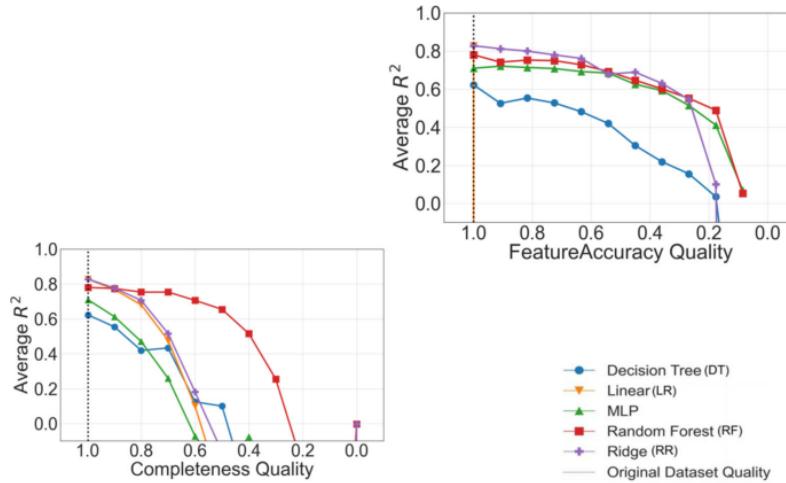


4.5.4 List of blocking and Non-blocking operations

- Blocking
 - Duplicate Removal
 - Sort
 - Aggregation
 - Join
 - Intersect
 - Difference
 - Unpivot (transform rows into columns)
- Non-blocking
 - Field Value Alteration
 - Single Value Alteration
 - Sampling
 - Dataset Copy
 - Duplicate Row
 - Router
 - Union
 - Field Addition
 - Datatype Conversion
 - Field Renaming
 - Projection
 - Pivot (transform columns into rows)
 - Extraction
 - Loading

5 Data Quality

La calidad de los datos tiene un **impacto económico**. Es importante darse cuenta que tiene un impacto en el coste del día a día de la empresa y también desde el punto de vista positivo perdemos ingresos y ventas. Si aumentamos la calidad reduciremos costes y aumentaremos los ingresos.



Desde un punto de vista más técnico podemos ver las gráficas. Tienen el R^2 de los diferentes modelos en el eje y. Como podemos ver dependiendo de la complezidad de los datos nos afecta al R^2 del modelo. Como menos completos sean los datos menor es el R^2 . Esto también sucede con la *accuracy* de los atributos. A veces perdemos mucho tiempo iterando los hiperparámetros o probando modelos y en verdad **lo que tendríamos que hacer es mejorar la calidad de los datos** porque tendrá un impacto mucho mayor.

Tenemos que **determinar para qué uso queremos usar los datos**. La calidad de los datos es un proceso costoso y tenemos que considerar qué cantidad de recursos destinamos ello. En general tener unos datos completos y de calidad mejora en todos los sentidos nuestro modelo.

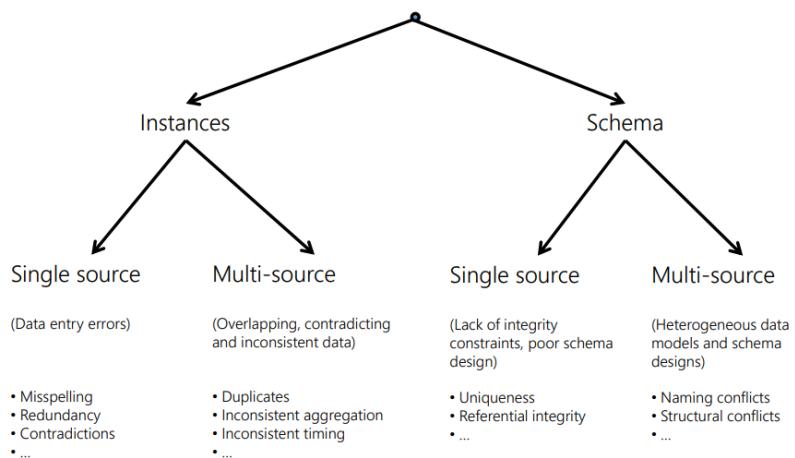
Los **fallos más habituales** son que faltan datos, o que estos datos estén obsoletos (ya no corresponden a la realidad actual). También que los datos no sean lo suficientemente acurados. El **efecto** que esto tiene es que se ahorra costes si aumenta la calidad de datos, se incrementa la eficiencia y la reputación de la empresa mejora (nuestros clientes/socios deben creer que tenemos datos correctos). Podemos perder oportunidades de negocio. Además las usamos para tomar decisiones, si los datos son incorrectos nuestras decisiones probablemente también.

Los problemas pueden venir de cualquier sitio:

- **Carga inicial de los datos:** si hacemos una conversión de datos inicial o si los ponemos a mano nos podemos equivocar. Haciéndolo con *batch* (paquetes de datos que cargamos de manera automática), con interfaces en tiempo real o con diferentes sistemas puede llevar a errores.
- **Preproceso:** si el proceso es manual o automático introducirá errores. Si intentamos limpiar los datos podemos introducir otros errores (por una parte mejoramos pero por la otra no), si purgamos también podemos estar perdiendo datos importantes (errores por borrar demasiado).

- **Inacción:** si no hacemos nada la calidad de los datos se ve repercutida. Hay cambios en el mundo, en la base de datos, en el entorno, etc. que no se capturan si no hacemos nada.

5.1 Data Conflicts



5.2 Quality Measures

Vamos a ver como podemos medir la calidad de nuestros datos, hay muchas perspectivas/dimensiones de calidad de datos y dentro de estas dimensiones hay muchas métricas. Las 3 más relevantes son la **completitud**, la **precisión** y la **consistencia de los datos**. Dentro de la precisión podemos incluir la precisión *temporal*, que es cómo de actualizados están nuestros datos en la BD.

Hay otras dimensiones como:

- **Redundancia**
- **Legibilidad**
- **Accesibilidad**
- **Utilidad**
- **Confianza**

5.2.1 Completeness

Primero, es importante **considerar si existe la posibilidad de que falten entidades del mundo real** que no estén representadas en nuestra base de datos. Al abordar este escenario, entramos en lo que se conoce como la "**Open World Assumption**" (**OWA**), lo que implica que nuestra base de datos no es cerrada. En otras palabras, estamos abiertos a la posibilidad de que existan otros objetos en el mundo real que no estén reflejados en nuestra base de datos. En este contexto, es fundamental examinar cuidadosamente los objetos del mundo real y determinar cuáles de ellos no están presentes en nuestra base de datos.

En contraste, la "**Closed World Assumption**" (**CWA**) representa el escenario opuesto. Aquí, asumimos que nuestro mundo es cerrado, lo que significa que los únicos objetos que existen en el mundo real son aquellos que están registrados en nuestra base de datos. Bajo esta premisa, no deberíamos tener entidades faltantes en términos de

filas (aunque podríamos enfrentar la ausencia de ciertas columnas o valores dentro de los atributos). Es importante comprender y diferenciar entre estos dos enfoques, ya que pueden tener implicaciones significativas en el tratamiento y la interpretación de los datos.

$$Q_{C_m}(A_i) = \frac{|R(\text{NotNull}(A_i))|}{|R|}$$

Porcentaje de valores que tenemos del atributo. Podemos hacer lo mismo para la tabla entera, cogemos la conjunción para todos los atributos de la tabla. Nos dirá el porcentaje de filas que no tienen ningún atributo nulo.

$$Q_{C_m}(R) = \frac{|R(\wedge_{A_i \in R} \text{NotNull}(A_i))|}{|R|}$$

5.2.2 Accuracy

Nos indica el grado de error en nuestros datos.

- $e_A = |\mathbf{v}_A - \mathbf{v}_{\text{RealWorld}}|$, para llevar a cabo esta medida, es necesario conocer el valor del mundo real, lo que implica realizar un muestreo de estos objetos o atributos. Luego, se compararía el valor real con el valor que tenemos en la base de datos y se calcularía la diferencia.
- $Q_A(A_i) = |\mathbf{R}(e_{A_i} \leq \epsilon)|/|\mathbf{R}|$, miramos si el error es menor que un cierto ϵ , si lo es, seleccionamos estas filas de la tabla y contamos cuantas hay que tienen un valor aceptable para este atributo y entonces dividimos entre el total de filas de la tabla.
- $Q_A(R) = |\mathbf{R}(\wedge_{A_i \in R} e_{A_i} \leq \epsilon)|/|\mathbf{R}|$, podemos hacer lo mismo para toda la tabla, debemos hacer la conjunción para todos los atributos de la tabla, miramos si su error está dentro de este intervalo que consideramos aceptable. Si una fila tiene todos los atributos dentro de esta precisión contamos la fila.

5.2.3 Timeliness (Freshness)

Temporalidad o frescura de los datos. Necesitamos dos datos:

- $age(v) = \text{now} - \text{TransactionTime}$, edad del dato, momento actual menos el tiempo de transacción (cuando se ejecutó la última modificación sobre este dato en nuestra BD). Aunque tenga una edad alta no tiene porqué estar obsoleta, depende de cada cuando deber ser modificado, cada cuanto varia este dato.
- $f_u(v) = \text{updates per time unit}$, frecuencia con la cual esperemos que este valor cambie (e.g Fecha de Nacimiento no esperamos que cambie). Si la edad hace 5 años que no cambia, este dato esta obsoleto, ya que esperamos que cambie cada año.

Teniendo en cuenta estas dos medidas podemos calcular lo siguiente:

- $Q_T(v) = (1 + f_u(v) \cdot age(v))^{-1}$, multiplicamos la frecuencia esperada de cambio multiplicado por la edad, le sumamos 1 para evitar divisiones por 0 y después hacemos la inversa. Si esperamos que un valor cambie 3 veces por año y la edad de esto es 1 año entonces daría $1/4$.
- $Q_T(A_i) = \text{Avg}_{v \in \mathbf{R}[A_i]} Q_T(v)$ calidad temporal de un atributo entero, hacemos el promedio de cada uno de los valores
- $Q_T(R) = \text{Avg}_{A_i \in R} Q_T(A_i)$, hacemos lo mismo para toda la relación

5.2.4 Consistency

La consistencia se basa en medir una serie de **restricciones de integridad** (business rules):

- **Entidad:** ver si conocemos el identificador de la fila.
- **Dominio:** ver si los enteros son enteros, los reales son reales, ...
- **Referenciales:** llaves foráneas.
- **User-defined:** *checks* que podemos poner en la tabla.

También hay que tener en cuenta la **coincidencia de las copias**.

- **Temporal:** si una copia no se ha actualizado y la otra sí.
- **Permanente:** si una copia no se actualiza nunca y la otra si se va actualizando.

$$Q_{C_n}(R, B) = \frac{|R(\wedge_{rule \in B} rule(A_1, \dots, A_n))|}{|R|}$$

R es la tabla y B el conjunto de reglas (es lo que medimos). Hacemos la conjunción para todas las reglas que hay y miramos si estas reglas se cumplen para todos los atributos. Cuantas tuplas hay que cumplan todas las reglas. Porcentaje de tuplas que cumplen todas las restricciones de integridad que tenemos.

5.2.5 Trade-offs between dimensions

Darse cuenta de que **hasta cierto punto, estas metas son contradictorias**. No podemos esperar maximizar todas ellas simultáneamente. Si intentamos maximizar la frescura de los datos, es decir, actualizarlos lo más rápido posible una vez que tenemos información nueva, corremos el riesgo de cometer errores de precisión. Existe la posibilidad de que insertemos valores demasiado apresuradamente, lo que podría generar problemas de consistencia en la base de datos.

Por otro lado, si nos enfocamos en mejorar la completitud y la precisión de los datos, necesitaremos más tiempo, ya que los valores se actualizarán de manera más lenta. Cuando intentamos mejorar la completitud de los datos mediante la imputación de valores faltantes, es probable que surjan errores de precisión y consistencia, y viceversa.

Timeliness \Leftrightarrow Accuracy, Consistency and Completeness

Completeness \Leftrightarrow Accuracy and Consistency

5.3 Quality Rules

Relacionado con la consistencia de la BD tenemos un conjunto de reglas de calidad y por lo tanto es importante analizar que características tienen o pueden tener.

5.3.1 Restricciones de integridad en RDBMS

- **Intra-Attribute:** afectan solo a un atributo. Control de dominio o outliers y presencia de valores nulos.
- **Intra-Tuple:** afectan a una tupla entera como podría ser los checks.
- **Intra-Relation:** afectan a todas las tuplas de una relación, seria el caso de llaves primarias y unicidad dentro de los atributos (sin valores repetidos). También los *triggers* temporales o de tipo estado (e.g definir un trigger que no permita que bajen los sueldos).
- **Inter-Relation:** afectan diferentes relaciones como las llaves foráneas y las assertions.

En algunos casos se puede formalizar mediante dependencias:

- **Dependencias multivaluadas:** que un atributo tenga un cierto valor hacer que otro atributo pueda tener solo algunos valores (determina muchas atributos e.g sabiendo el DNI sabemos qué idiomas habla una persona). Como caso degenerado tenemos las **dependencias funcionales**, que si un atributo tiene un valor, otro atributo solo puede tener un valor. Esto implementa llaves foráneas y *unique*.

$$t1.X = t2.X \implies t1.Y = t2.Y$$

- **Dependencias de inclusión:** para modelar de manera matemática las llaves foráneas. Si tenemos una llave foránea en la relación R, los valores de esa llave foránea serán un subconjunto de los valores de la *primary key* de la otra tabla.

$$R.X(fk) \subset S.Y(pk)$$

5.3.2 Problems in the rules

Pueden dar problemas de:

- **Contradicciones:** hace que no podamos insertar algunas filas

$$CHECK(a < 10 \text{ AND } a > 20)$$

- **Redundantes:** hacen que el rendimiento empeore
 1. $CHECK(a > 20)$
 2. $CHECK(a > 10)$
- **Imperfecciones:** Puede ocurrir que estemos intentando evitar ciertas filas, pero nuestras reglas y restricciones de integridad no logren evitar los estados que deseamos prevenir o, en su lugar, impidan estados que no teníamos la intención de evitar.

Respecto las dos primeras podemos definir una serie de propiedad lógicas de las reglas o restricciones de integridad.

- **Satisfacción del esquema:** un esquema es satisfactible si podemos poner una fila en una tabla (en cualquiera de ellas).
- **Lifeliness:** referencia a tablas o vistas, hay que poder inserir una fila en una tabla concreta.
- **Redundancia:** una restricción de integridad es redundante si la consistencia de la BD no depende de esta, porque las demás restricciones ya hacen su trabajo.
- **State-reachability:** definido por un conjunto de tuplas. Quiere decir que podemos encontrar un estado consistente de la BD en la cual estén estas tuplas (y puede que más).
- **Contenimiento de la query:** el resultado de una consulta siempre un subconjunto del resultado de otra consulta.

Es importante darse cuenta que en cualquier caso hablamos siempre de BD consistentes, si la BD no es consistente (se violan las restricciones de integridad) no tiene sentido mirar las propiedad lógicas.

5.3.3 Fine-tuning imperfections

Puede ser que algunas tuplas que estén correctas hacen que están reglas de integridad se disparen (falso positivo) o al revés, filas que son incorrectas no se detectan

(false negative). Como las reglas de integridad no se violan muy a menudo, no debería haber demasiados falsos positivos. Los falsos negativos si hacemos un *sampling* y no encontramos ninguno probablemente no hay demasiadas violaciones.

Lo que debemos hacer es:

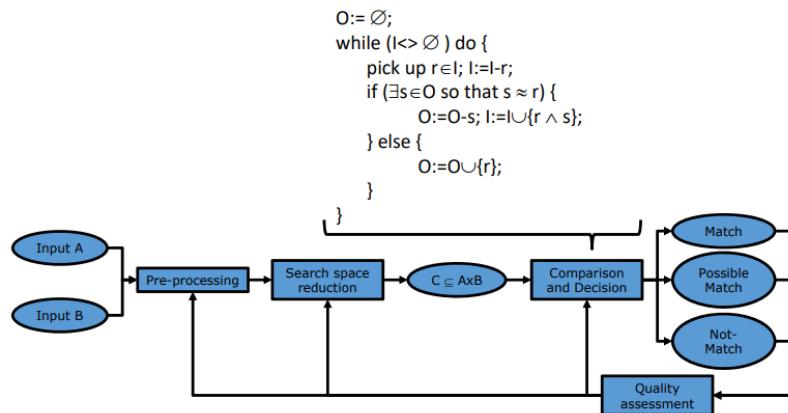
1. Identificar imperfecciones
2. Analizar si hay algún patrón en las imperfecciones
3. Mejorar las reglas y volver a 1

5.4 Quality improvement

Veremos que podemos hacer para mejorar la calidad de nuestros datos. Una de las cosas que necesitaremos es identificar objetos en BD diferentes. Si queremos mejorar la calidad tenemos 2 maneras de hacerlo:

- **Imputar valores** sin ninguna información adicional, simplemente buscando el cambio mínimo o buscando una cierta distribución de los datos de un mismo atributo o de diferentes atributos a la vez.
- **Buscar fuente de información** que esperemos que nos de más información de la que tenemos y cruzar o completar con esta fuente. Nuestra fuente original tiene problemas en algunos atributos y buscamos una fuente de datos que tenga mejor información de estos atributos en concreto.
 1. Encontrar donde está el problema (atributo)
 2. Buscar fuente que sea más confiable por la razón que sea y el coste que tenga (no tiene por qué ser gratuita)
 3. Identificar que dos tuplas en los dos conjuntos de datos realmente coinciden con el mismo objeto del mundo real. Primero deberemos hacer alguna normalización/estandarización de los identificadores porque no tienen porque ser el mismo.
 4. Juntar los registros.

5.4.1 Process for Object identification



- **Input A:** fuente original
- **Input B:** fuente de datos complementaria que nos da la información adicional que tiene mejor calidad
- **Pre-processing:** Normalización/estandarización de los identificadores u otros atributos.

- **Search space reduction:** si queremos comparar todas las tuplas con todas las tuplas de la otra fuente el coste computacional es muy elevado.
- $C \subset A \times B$: analizaremos un subconjunto del producto cartesiano. Este subconjunto lo deberíamos de formar de manera que no perdamos ninguna pareja que nos interese.
- **Comparison and Decision:** tenemos que comparar de estas parejas de A y B, se hace con el algoritmo *R-shush* (tenemos una función de comparación). Esto nos puede dar 3 resultados:
 1. **Match:** las dos tuplas se refieren al mismo objeto.
 2. **Possible Match:** hay una posibilidad de que las dos tuplas se refieren al mismo objeto.
 3. **Not-match:** las dos tuplas **no** se refieren al mismo objeto.
- **Quality assessment:** manualmente miraremos si esto nos está dando un resultado aceptable, si no nos lo está dando deberemos reconsiderar el preproceso, que el espacio no sea demasiado reducido o que la función de comparación funcione bien.

5.4.2 Search space reduction

Hay 3 técnicas conocidas y estudiadas:

- **Blocking:** participamos los dos conjuntos según una clave (atributo) por ejemplo equipos de fútbol.
- **Sorted neighbourhood:** ordenar de alguna manera, en orden alfabético por ejemplo.
- **Pruning:** hacer algún tipo de heurística, por ejemplo no comparar los porteros con los jugadores.

5.4.3 Comparison/Similarity function

Necesitamos una función de comparación, hay muchas opciones.

- **Distance-based**
 - Decide that two records represent the same entity if their distance is below a threshold (after removing affixes)
 - Hamming distance
 - Edit distance (insert, delete and replace)
 - Smith-Waterman algorithm (assign weights)
 - n-Grams comparison
 - Jaro algorithm (insert, delete and transpose)
 - Compare lists of items
 - Jaccard distance
 - Token Frequency-Inverse Document Frequency (TF-IDF)
 - May use phonetics
 - Soundex code
- **Rule-based**
 - Depending on the concrete attributes (e.g., ignoring middle name)
- **Probabilistic techniques** (which require a threshold)
 - Based on conditional probabilities
- **Classification-based**
 - Provide positive and negative training pairs of instances (to train a classifier)

6 Schema and Data Integration

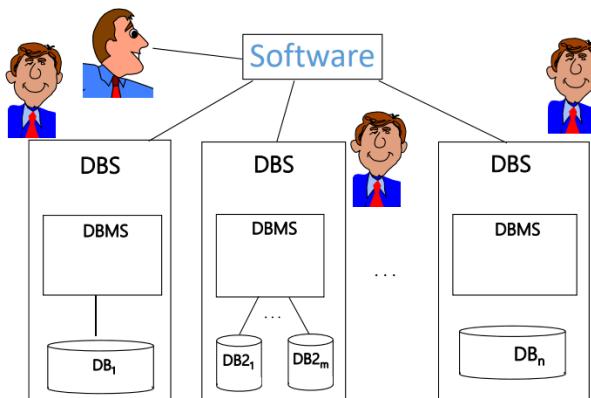
Problema de la integración de los datos: Lo que queremos hacer es una consulta y para resolverla necesitamos acceder a diferentes fuentes de datos.

- El problema no es como nos conectamos a las bases de datos (se asume ya desde un inicio).
- El problema no es el envío de los datos entre sistemas.
- El problema no es el acceso remoto a las BD. Se puede hacer con cualquier tipo de driver (e.g JDBC)
- El problema no es tener múltiples clientes/servidores.
- El problema no es que tengamos un SGBD distribuido.

El problema es que queremos **hacer una consulta, queremos tener una respuesta y para tenerla tenemos que acceder a múltiples BD.** e.g. los atributos de las diferentes BD pueden referirse a lo mismo pero con valores diferentes en algunos casos.

Tres soluciones posibles a este escenario:

- **Hacer a mano las queries por separado en las diferentes BD.** Para hacerlo que la persona tiene que saber un poco de todo (las fuentes, los modelos, el lenguaje, etc.). Tiene que dividir la consulta en las diferentes consultas para cada una de las BD y el resultado integrarlo en un único resultado. *Inviável para gran número de fuentes de datos.*
- **Crear una nueva BD** contenido toda la información necesaria (**proyecto de migración** de los datos, ETL p.e.). Se tiene que modificar las aplicaciones para acceder a esta nueva BD en lugar de las fuentes de datos. Se tiene que hacer un *testing* de todo y pondríamos en marcha esta fuente de datos única donde todo el mundo trabajaría con esa.
- **BD distribuida:** Capa de **software** que (auto o semiautomáticamente) es capaz de dividir la consulta y integrar las respuestas. Posible hasta cierto punto. La capa de software define dos niveles de acceso:
 - Los usuarios que acceden a través de la capa de software.
 - Los usuarios que ya utilizaban las BD desde antes. Estos se mantienen.



Hay usuarios pre-existentes que continúan trabajando como lo hacían antes. Lo que añadimos es una capa de software donde el usuario quiere hacer una consulta integrada (una consulta una respuesta). Este software divide la consulta en consultas más pequeñas sobre cada fuente. Cada fuente devuelve la respuesta a la capa de software y esta al usuario.

6.1 BD distribuida

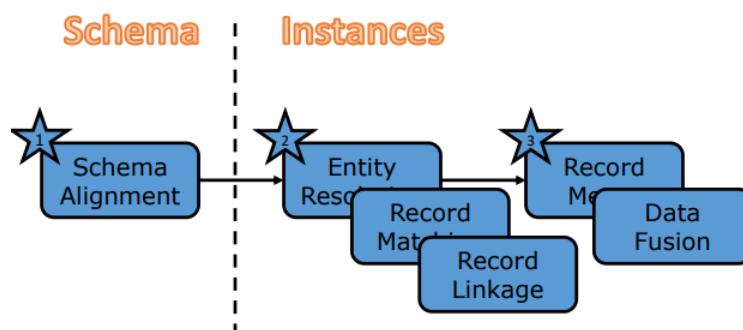
Son diferentes **BD interrelacionadas, distribuidas en una red** y que se quiere tan **transparente** como sea posible. Se asume que todo es homogéneo y un sistema único aunque no se especifica en la definición formal.

Se pueden clasificar las diferentes BD distribuidas según su autonomía (de más a menos). La autonomía nos lleva a que se puedan hacer las cosas diferentes, por lo tanto tenemos heterogeneidad.

- **heterogeneidad de sistema:** En un sistema, vemos que tiene varias BD dentro y son diferentes. Cada uno con sus características y se tiene que solventar de alguna manera. *Esta es la heterogeneidad fácil.*



- **heterogeneidad de semántica:** Independencia para funcionar utilizando formatos, esquemas, etc. diferentes de los datos. Esto nos lleva a que cuando se busque interpretar, cruzar estos datos y acceder de forma conjunta, se tiene que resolver esta heterogeneidad (del significado de los datos). Para hacerlo se tiene que primero integrar la parte del esquema y luego la parte de las instancias:
 - **Esquema:** se tienen que encontrar las tablas que contienen información común (que hacen referencia al mismo tipo de objeto/identidad del mundo real) y también los atributos (mirar si son los mismos o no). *No es fácil de encontrar.*
 - **Instancia:** Una vez encontrado que dos tablas contienen información del mismo tipo de entidad. Se tiene que ver si las entidades concretas que hay dentro (tuplas) realmente son las mismas o no (**Entity resolution = Record matching/linkage**).
 - **Record Merge:** Coger todos los atributos de las filas que coinciden y ponerlos juntos. La idea es una vez tenemos fusionados los datos de todas las entidades que realmente coinciden ya seremos capaces de devolverle al usuario una respuesta única para su consulta.

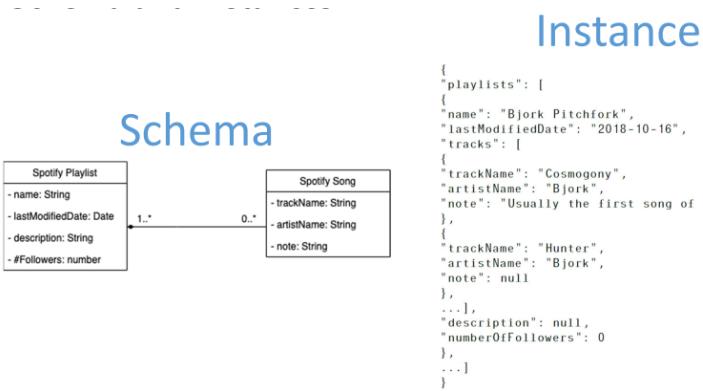


6.2 Kinds of Heterogeneity

El problema real que tenemos es la heterogeneidad de semántica (la del significado de los datos, que quieren decir), no de sistemas.

6.2.1 Schema and instances

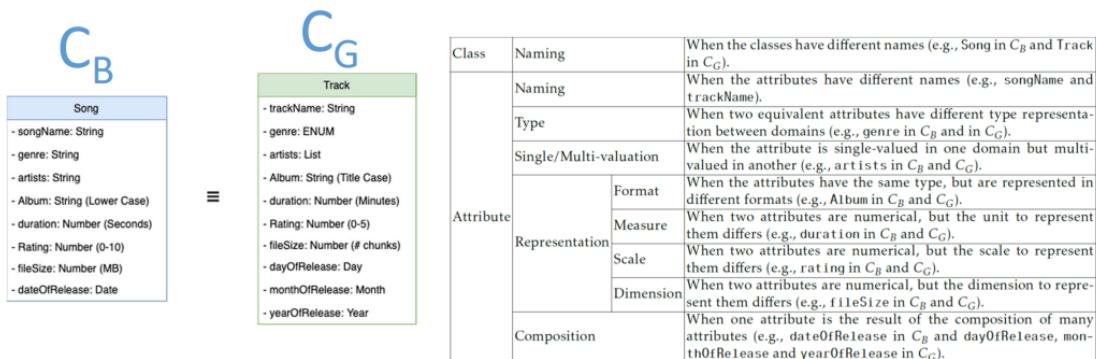
Los problemas de heterogenidad aparecen independientemente de la representación de los datos (esquema, instancia)



6.2.2 Intra-class heterogeneity

Entre las diferentes tablas que se refieren al mismo concepto.

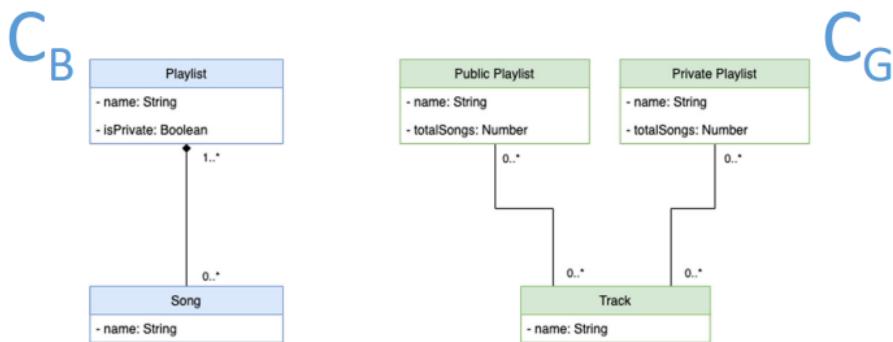
- El nombre de ambas tablas tienen un nombre diferente.
- Entre atributos:
 - El **nombre** entre los atributos es distinto (*songName* - *trackName*).
 - El **tipo de dato** de los atributos es distinto (*String* - *ENUM*).
 - El atributo puede ser **multi o univaluado** (*String* - *List*).
 - La **representación** del atributo: (formato (*Upper, Lower*), medida (*sec, min*), escala (*0-5, 0-10*), dimensión (*MB, GB*))
 - De **composición**. P.e que la date de formato "dd-MM-yyyy" este separado en tres atributos para cada componente.



6.2.3 Inter-class heterogeneity

Relación entre las clases.

- **División de la clase en subclase.** Se tendría que ver si la unión de las subclases corresponde a la clase. (*Playlist - Public Playlist + Private Playlist*)
- **De agregación:**
 - **Composición:** 1 playlist guarda dentro toda la información de las canciones (por el rombo negro de la flecha). En el de la derecha como no tienen el rombo negro lo que guardarían las playlist serían punteros hacia los diferentes tracks.
 - **Datos derivados:** en C_G el `totalSongs` depende de la tabla Track, pero nos podemos guardar ese valor. En el caso de C_B no perdemos ese valor, cuando queremos el número de canciones contamos la tabla Song.



Super/Subclass of		When a Class in a schema is a generalization or specification of a class in another (e.g., Playlist in C_B and Public/Private Playlist in C_G).
Aggregation	Composition	When a class is composed by an aggregation of another class in one domain, but is an independent class in another (e.g., Song is aggregated inside Playlist in C_B while Track has simple associations with Public/Private Playlist in C_G).
	Derivation	When the characterization of a class is derived from the aggregation of another (e.g., Public/Private Playlist in C_G have <code>totalSongs</code> , an attribute defined by the aggregation of Track in C_G . While in C_B such dependency is absent).

6.2.4 Data-Metadata heterogeneity

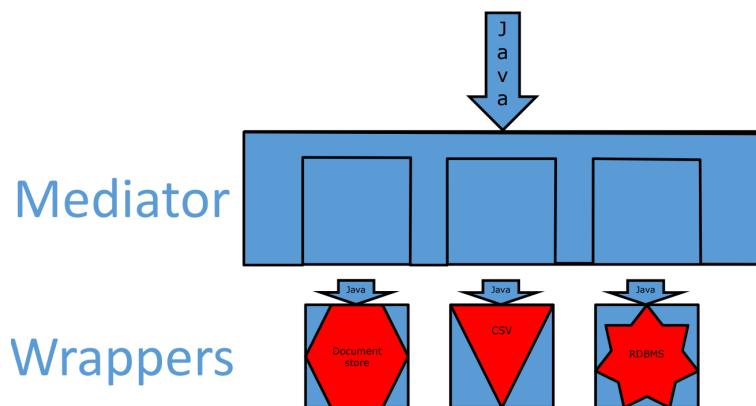
Ocurre cuando en un lado se guardan datos y en el otro meta-datos. P.e. *Rock*, *Pop*, *Rap* son metadatos (ya que se refieren al nombre de la tabla) y en la otra representación serían instancia (datos).



La figura de la izquierda (Rock, Pop, Rap) son metadatos.

6.3 Overcoming System Heterogeneity

Se hace mediante una arquitectura de tipo **Wrappers-Mediator**. Lo que queremos es crear una capa de software (*Mediator*) que lo que hace es ofrecer al usuario (que quiere acceder al sistema de forma integrada) una interficie tipo JAVA en la cual puede resolver sus consultas que necesiten acceder a los sistemas (fuentes de datos). El **Mediator** tiene que acceder a los tres sistemas, pero como los sistemas no tienen la misma estructura, se necesita el **Wrapper**.



Wrapper es una capa de software que se encarga de esconder la complejidad de cada uno de los sistemas al **Mediator**. El **Mediator** vería los tres sistemas como si fueran absolutamente idénticos (aunque los sistemas tengan características diferentes). Unifica la interficie hacia las fuentes.

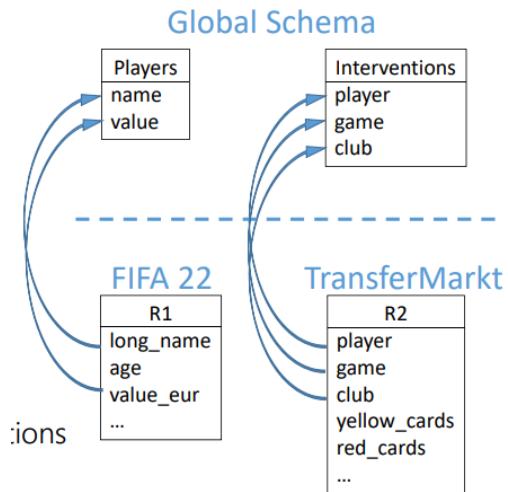
Por lo tanto el mediador es el encargado de deshacer la consulta del usuario en las consultas para cada una de las fuentes y después coger los resultados de cada una de las fuentes y ponerlos juntos para conformar la respuesta única. Los wrappers serían los encargados de simplificar la vida al mediador y que este no tuviera que distinguir el sistema de cada una de las fuentes.

6.4 Schema Integration

La integración del esquema es el primer paso para integrar los datos. Pero antes se deben alinear los esquemas y crear los **mappings** (las correspondencias entre las fuentes y el esquema global que se le ofrece al usuario).

6.4.1 Alignment Process

Como entrada, tiene los esquemas de las diferentes fuentes. El resultado obtendríamos sería el esquema global/integrado/mediador (que utiliza el usuario en las consultas). Después se buscarían las correspondencias entre los atributos de las fuentes de datos y el esquema global definido. Finalmente se tendrían que ver que transformaciones padecen los atributos (cambio de moneda, normalización, etc.).



6.4.2 Mapping

Tipos de mappings se definen y que mecanismo utilizamos para implementarlos:

- **Consistente/coherente (sound):** En el sentido de que la consulta que nos da todos los datos de la fuente es un subconjunto de la consulta que quiere el usuario (hay datos de otras fuentes que no se incluyen en la consulta).

$$q_{\text{obtained}} \subset q_{\text{desired}}$$

- **Completa:** En el sentido que lo que quiere el usuario final es un subconjunto de todo lo que tenemos en la fuente. Hay cosas en la fuente que el usuario no está interesado.

$$q_{\text{desired}} \subset q_{\text{obtained}}$$

- **Exacta:** Cumple las dos anteriores.

$$q_{\text{desired}} = q_{\text{obtained}}$$

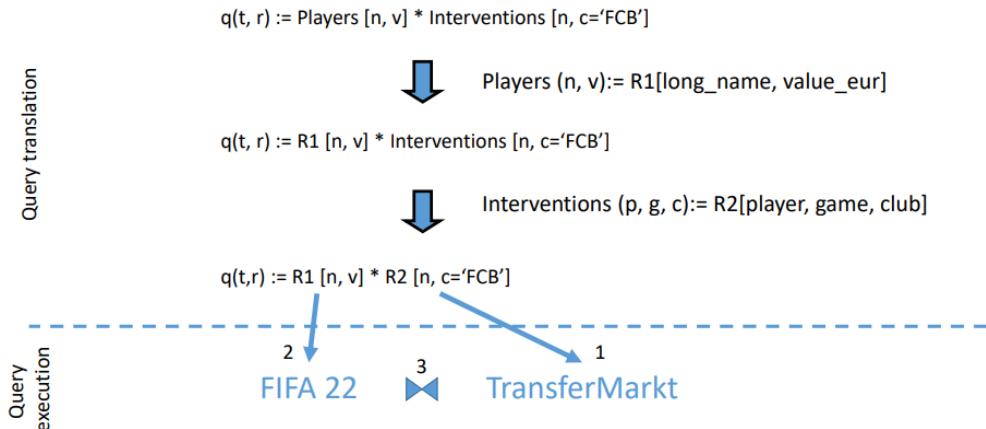
Como se implementan estas correspondencias en el mediador? La solución más simple es la **Global As View**, donde el esquema global se expresa como una vista sobre las fuentes de datos.

- Se define como una vista sobre las fuentes.
- Relativamente sencillo pero se tiene que ir definiendo uno por uno cada elemento del esquema global con su consulta correspondiente (mapping).
- Lo bueno es que el mecanismo de consulta para implementar el mediator es muy sencillo (lo mismo que los SGBD para traducir las vistas).
- Rígido a los cambios de las fuentes.

6.4.3 Example of Global as View (GAV)

- Global schema
 - Players (name, value)
 - Interventions (player, game, club)
- Local schemas
 - FIFA 22
 - R1 (long_name, age, value_eur, ...)
 - TransferMarkt
 - R2 (player, game, club, yellow_cards, red_cards, ...)
- Mappings
 - Players (n, v):= R1[long_name, value_eur]
 - Interventions (p, g, c):= R2[player, game, club]

Tenemos en forma de tablas nuestros esquemas globales (jugadores y intervenciones) y las fuentes de datos (FIFA 22: R1 y TransferMarket R2). El mapping es simplemente una consulta que implementamos con álgebra relacional. Estamos haciendo una proyección de la fuente cogiendo los atributos que nos interesan.



Debemos traducir la consulta que esta expresada en términos del esquema global a las fuentes de datos. El usuario final expresaría la consulta con esa terminología.

El hecho que la variable n sea la misma significa que es el atributo de join. El $c = 'FCB'$ indica una selección. Una vez que el usuario nos ha indicado su consulta utilizamos los mappings para traducir las tablas al formato correcto sobre las fuentes de datos. El esquema global es una vista, que no es más que una consulta.

Una vez hecho esto pasamos la siguiente fase (todo lo anterior lo hace el mediator). En este caso tendríamos que decidir a que fuente accedemos primero (R1 o R2), como hay selección en R2 seguramente se empezaría por esa (ya que esperamos que tenga menos filas). Entonces haríamos una consulta al wrapper de TransferMarket. Una vez tengamos el resultado hacemos la consulta sobre el wrapper de FIFA22 y una vez tengamos ambos resultados haríamos el *join* entre ellos para obtener el resultado único para el usuario.

6.5 Data Integration

Mirar las instancias de las tablas para ver si coinciden y representan el mismo objeto del mundo real. Para hacer esto hay que seguir dos pasos:

1. **Entity Resolution (Record matching)**: Ver cuando dos filas representan el mismo objeto. Necesitamos una función que identifique los objetos, cuando dos filas correspondan al mismo objeto nos lo diga.
2. **Fusionar**: Única fila que represente las múltiples filas que coinciden. Deberíamos homogenizar los esquemas de estas tuplas.

6.5.1 Entity resolution

Lo que nos interesa es ver si dos filas corresponden al mismo objeto. Varios problemas dependiendo del tipo de datos (error de escritura, cambios temporales, abreviaciones, variantes y más mamadas). Se busca simplificar y tener una normalización de los datos.

Función de similitud \approx :

- Basadas en distancias (*Hamming, Levenshtein, Jaccard* $\frac{|A \cap B|}{|A \cup B|}$)
- Basadas en heurísticas
- Probabilísticas
- Modelos de clasificación

Función de fusión \wedge : Si coinciden, FANTÁSTICO! Pero si no hay varias posibilidades:

- Generar un valor null.
- Quedarme los múltiples valores.
- Quedarme con el de la fuente más confiable.
- Usar *crowdsourcing*. Preguntarle al proletariado.

6.5.2 Algoritmo R-Swoosh

Para un único DB con repetidos dentro: O es el output, I input.

```
O := {}
while I ≠ {} do
    escoger r ∈ I
    if (exists s ∈ O tal que s ≈ r) then
        I := I - r; O := O - s; I := I ∪ {r ∧ s}
    else
        I := I - r; O := O ∪ {r}
    end if
end while
```

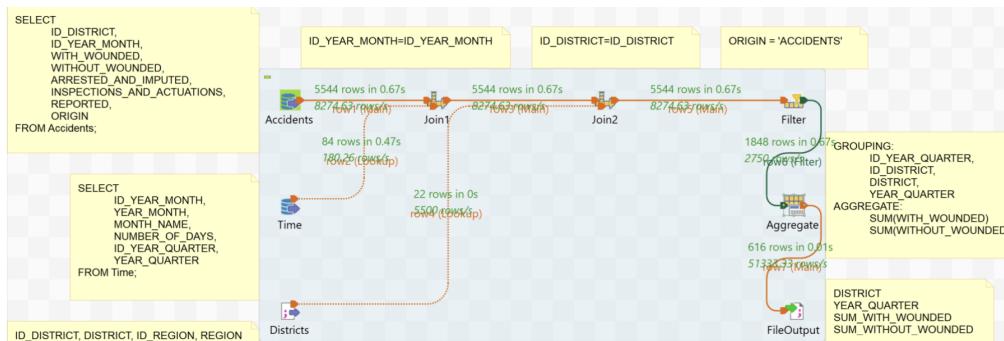
El resultado del *if* se vuelve a meter al input la fusión de *r* y *s*.

7 Sessió de dubtes

Quina ventatge té fer una vista vs una consulta?

Desde el punt de vista de optimització, fer una vista vs una consulta es el mateix (les vistes es diuen *named queries*). La vista et dona facilitat d'ús, seguretat (donar permisos a la vista i no a l'usuari). Ara, una vista materialitzada té la taula de respostes guardades, i quan es fa la consulta sobre la vista, es consulta directament sobre el resultat pre-materialitzat. Si el SGBD és prou bò, mira si els dos resultats coincideixen, i automaticament, anirà a buscar les dades de la vista.

Exercici 3 examen parcial 2022 Given the ETL below, where the stickers indicate the attributes and conditions of the nearest node, briefly explain how you would optimize it or justify why you think it is already optimal. Explicit any assumption you need to make and annotate any change in the same diagram to facilitate the explanation.

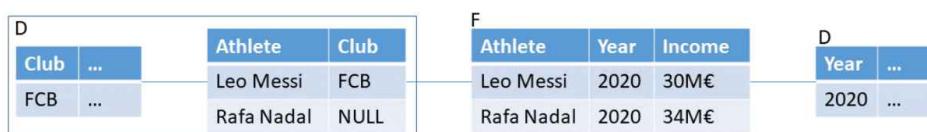


Moure el filter d'origin dins de la primera query en forma de WHERE. En cas que alguns dels JOINS redueixi el nombre de rows, aquest hauria d'anar primer, ja que reduiria el nombre de files que tractem.

Podem moure el aggregate entre els dos joins, ja que no necessitem el districte, només l'ID, ja que el districte està lligat a ell. Per tant podem treure DISTRICT del aggregate i moure'l entre els JOINS.

Finalment, en els SELECT podem no demanar atributs que no s'utilitzen, com ARRESTED AND IMPUTED, INSPECTED, REPORTED, etc. Igualment amb el segon SELECT.

Ex. 1, parcial 2021 Identify the main problem in the multidimensional schema below, and propose a solution to solve it.



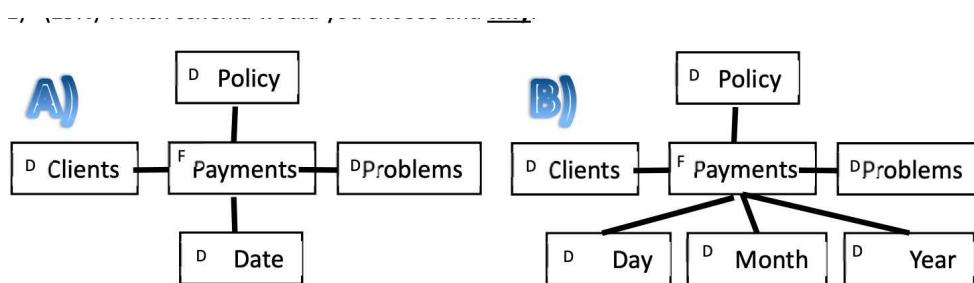
Que pasa si permetem que un jugador tingui més d'un club en una temporada? Suposem que no pot passar, que només canvia d'una temporada per l'altra. En aquest cas, tenim una *slowly changing dimension*. Una solució és ignorar el canvi. L'opció 2

seria posar el club actual i l'anterior. La tercera és modificar la clau primària, en comptes de posar el club com a PK, posem un timestamp, que representaria fins a quin moment va estar al club.

Si permetem que canvii a mitja temporada, la solució depen de la que haguem triat abans. Si hem decidit canviar la PK, podem solucionar-ho fàcilment.

Un altre problema és que un athleta no tingui equip. Si el Club es NULL, després no podrem agregar per clubs, llavors tindrem un problema de Falta de Completesa. Se soluciona amb un fantasma, creant un club fictici, per exemple TENISTES, que quan fem un JOIN no faci que la tupla de Nadal desaparegui.

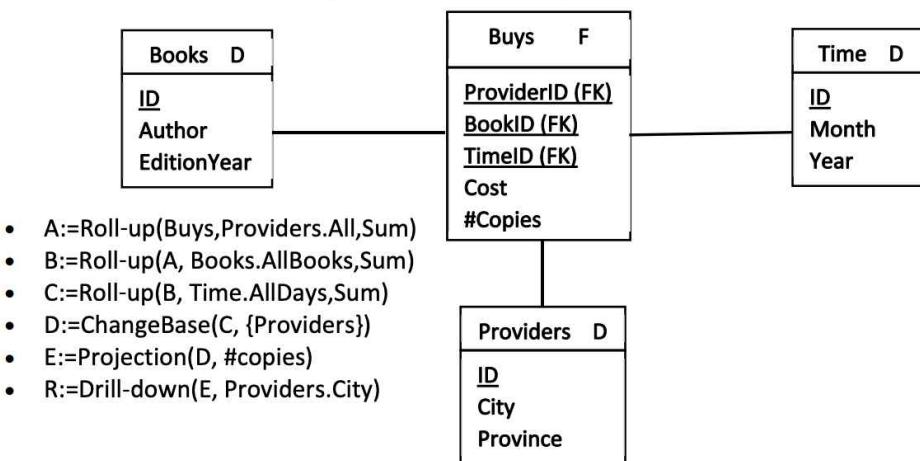
Ex.1, 2019. Which schema would you choose and why:



Si guardem els DATES, tindrem un identificador per cada dia, per tant tindrem rebundància de mes i any, mentres que si fem 3 dimensions DAY, MONTH, YEAR, tindrem només 30, 12, i x anys valors. La opció A ese com el producte caertesia de la b. En el primer hi ha rebundància, però en el segon hem de fer 3 joins en comptes d'1. Respecte el volum de dades, al ser dates, tampoc hi ha tantes. Si arribesim al nivell de minuts i segons si seria problematic.

Un altre cosa es el tema de les consultes. Si tenim l'esquema B podem fer consultes per mesos (e.g) més facilment, mentres que el A dificulta la consulta.

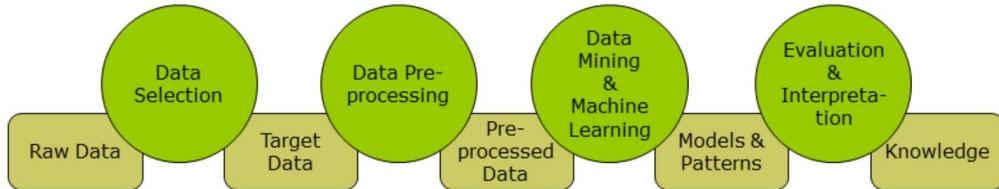
Ex.2, 2019. Given the multidimensional schema and the sequence of multi-dimensional operations, give the equivalent SQL query (simplify it as much as possible).



SELECT p.city, SUM(copies) FROM buys bu, providers p, WHERE bu.providerID == p.ID GROUP BY p.city El changebase ens diu quins dels atributs de les taules de dimensions em quedo, la projecció ens diu quins dels atributs de la taula de fets em quedo.

Appendix A Theoretical questions

1. Give examples of metadata that can be used at every step of the Knowledge Discovery in Databases process.



- **Selección de Datos:**
 - **Datos de Validez:** Información sobre la validez de los datos.
 - **Descripción de la Fuente de Datos:** Información sobre la fuente de los datos, incluyendo su origen, formato y método de acceso.
 - **Marca de Tiempo de la Recopilación de Datos:** Cuándo se recopilaron o extrajeron los datos.
 - **Método de Muestreo de Datos:** Detalles sobre cómo se muestrearon los datos, si es aplicable.
 - **Evaluación de la Calidad de Datos:** Metadatos que indican la calidad de los datos, incluyendo evaluaciones de completitud, precisión y confiabilidad.
- **Preprocesamiento de Datos:**
 - **Reglas de Negocio**
 - **Registros de Limpieza de Datos:** Registros de las operaciones de limpieza de datos realizadas, como el manejo de valores faltantes y valores atípicos.
 - **Descripciones de Transformación de Datos:** Información sobre cómo se transformaron, normalizaron o codificaron los datos.
 - **Notas sobre Ingeniería de Características:** Documentación de decisiones de creación o selección de características.
 - **Metadatos sobre Reducción de Datos:** Si se aplicaron técnicas de reducción de dimensionalidad, metadatos sobre el método de reducción y los parámetros utilizados.
- **Minería de Datos y Aprendizaje Automático:**
 - **Parámetros de Entrenamiento del Modelo:** Detalles sobre los parámetros utilizados para entrenar modelos de aprendizaje automático.
 - **Métricas de Rendimiento del Modelo:** Métricas utilizadas para evaluar el rendimiento del modelo (por ejemplo, precisión, puntuación F1).
 - **Versionamiento del Modelo:** Seguimiento de diferentes versiones de modelos junto con sus hiperparámetros.
 - **Puntuaciones de Importancia de Características:** Información sobre qué características tuvieron un mayor impacto en las predicciones del modelo.
- **Evaluación e Interpretación:**
 - **Criterios de Evaluación:** Explicación de los criterios utilizados para evaluar los resultados de la minería de datos o el aprendizaje automático.
 - **Notas de Interpretación:** Documentación de percepciones e interpretaciones obtenidas del análisis de datos.
 - **Metadatos de Implementación del Modelo:** Información sobre cómo y dónde se implementa el modelo para uso práctico.
 - **Información sobre el Ciclo de Retroalimentación:** Si corresponde, metadatos sobre cómo los resultados influyen en la toma de decisiones y la futura recopilación de datos.

2. Enumerate the advantages of having separate files (e.g., CSV) to be analyzed and compare it against the advantages of having a DBMS.

Advantages of using a DBMS	Advantages of using separate files
Estructurar los datos (índices) Integrated ² (centralizado) information SQL-able ³ Escalabilidad Propiedades ACID Uso de ML en el propio DBMS Gestión de permisos (GRANT, REVOKE)	Poca cantidad de datos Evita sobrecostes en casos concretos (ficheros temporales)

3. Explain in which sense each of the four characteristics of a DW in W. Inmon's definition increases the amount of data in the company.

- 3.1 **Subject-oriented:** puede haber duplicación de datos al usar las mismas tablas en distintos temas.
- 3.2 **Integrated:** Porque integramos datos de diferentes fuentes, no solo de los datos operacionales que tenemos sino también de *webs*, etc. y por lo tanto el conjunto de datos es mucho más grande.
- 3.3 **Time-variant:** Mantener datos a través del tiempo multiplica la cantidad de datos, uso de datos históricos que permitan ver la evolución de estos.
- 3.4 **Non-volatile:** Porque no borramos nada, lo único que hacemos es añadir. Si queremos modificar alguna cosa lo que hacemos es añadir una nueva versión del dato.

4. Explain the difference between "Time-variant" and "Nonvolatile" characteristics in the DW definition of W. Inmon. Illustrate it with an example different from that in the materials of the course.

Variante en el timepo hace referencia a que contiene datos históricos (por ejemplo datos de una empresa de hace 5 años) para poder hacer un buen análisis. **Non-volatile** significa que la información no se puede borrar ni modificar, lo único que se puede hacer es inserir nuevos datos.

Appendix B OLAP and the Multidimensional Model

B.1 Theoretical questions

1. Briefly explain the difference between the different kinds of multidimensional schemas:

a) Star vs. Snowflake

El esquema estrella tiene la tabla de hechos y las tablas de dimensiones alrededor con relaciones de muchos a uno. A diferencia del esquema snowflake, en el estrella no aparecen las jerarquías de agregación de las dimensiones. Por lo que dan más información al usuario.

b) Star vs. Galaxy

El esquema de galaxia son un conjunto de esquemas de estrellas, por lo que hay más de una tabla de hechos, que comparten algunas dimensiones. Están interconectadas.

2. Would you implement a snowflake schema in a Relational DBMS (RDBMS)?

No es buena idea porque haríamos muchos *joins*, que es la operación más costosa de las bases de datos relacionales. En este caso la alternativa que tendríamos es hacer una única tabla que englobe los atributos de todas las jerarquías de agregación de esa dimensión. No hacemos el snowflake (conceptualmente sí), no hace falta que cada concepto esté en una tabla diferente.

También tiene problemas, ya que repetiríamos muchos valores. Que preferimos, repetir los datos o separar las tablas y hacer muchos joins? La decisión depende de condicionantes que tengamos. Si tenemos que cambiar o modificar muchos los valores (sistemas operacionales) esto no es muy buena idea. Si no sucede esto es mejor la primera opción, aunque el volumen de datos sea más grande haremos menos *joins* y las consultas serán más rápidas.

Llevando esto al extremo, una mala idea sería poner todo en la tabla de hechos. Ya que si tenemos 4 dimensiones de 10 filas cada una tendríamos potencialmente 10000 filas en la tabla de hechos.

3. Consider a multidimensional schema with a dimension that does not have any attribute or aggregation hierarchy (e.g., order number). Briefly justify whether you would implement it like:

(a) A dimension table with only the primary key, pointed from the fact table.

(b) Only an attribute in the fact table, but not pointing to any dimensional table.

Es la mejor opción ya así no creamos una tabla de dimensión innecesaria con un solo atributo y hacemos menos *joins*. Esto es así porque los usuarios no modifican nada. Si estamos en un entorno OLT donde el usuario puede modificar la tabla, tener una dimensión extra nos permitiría gestionar mejor.

(c) No corresponding attribute or table in the star schema.

(d) Other option

4. One of the three necessary summarizability conditions is disjointness.

How can you implement a dimension with a level whose elements are overlapping avoiding summarizability problems? Give a concrete example using a UML class diagram with only two levels (you do not need to draw the whole snowflake schema).

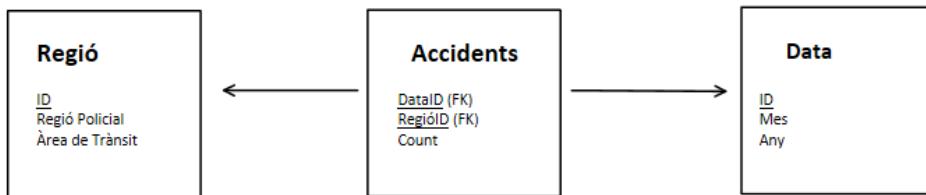
Esto solo sucede con relaciones muchos a muchos. Tenemos que crear una tabla intermedia de pesos con la cual tendremos que hacer *join* también.

B.2 Problems

- Identify factual and dimensional information in the following CSV sample file, and create a conceptual multidimensional schema.

ATTESTATION OF TRAFFIC ACCIDENTS

Month	Month name	Year	Police Region (RP)	Transit Regional Area (ART)	Number
1	Gener	2011	RP PIRINEU OCCIDENTAL	ART PIRINEU OCCIDENTAL	3
1	Gener	2011	RP GIRONA	ART GIRONA	10
1	Gener	2011	RP PONENT	ART PONENT	2
1	Gener	2011	RP CENTRAL	ART CENTRAL	7
1	Gener	2011	RP METROPOLITANA NORD	ART METROPOLITANA NORD	20
1	Gener	2011	RP METROPOLITANA SUD	ART METROPOLITANA SUD	10
1	Gener	2011	RP TERRES DE L'EBRE	ART TERRES DE L'EBRE	4
1	Gener	2011	RP CAMP DE TARRAGONA	ART TARRAGONA	5
2	Febrer	2011	RP PIRINEU OCCIDENTAL	ART PIRINEU OCCIDENTAL	3
2	Febrer	2011	RP GIRONA	ART GIRONA	6
2	Febrer	2011	RP PONENT	ART PONENT	4
2	Febrer	2011	RP CENTRAL	ART CENTRAL	1



- Identify factual and dimensional information in the following CSV sample file, and create a conceptual multidimensional schema.

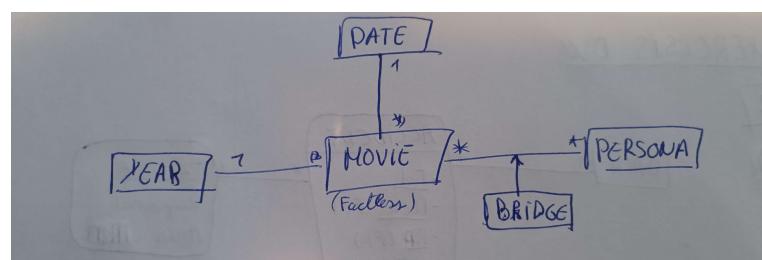
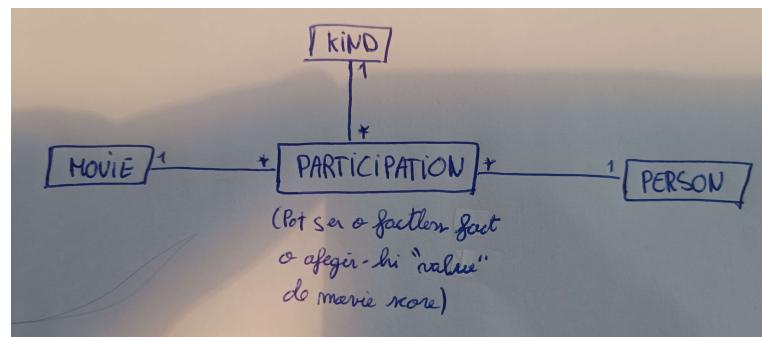
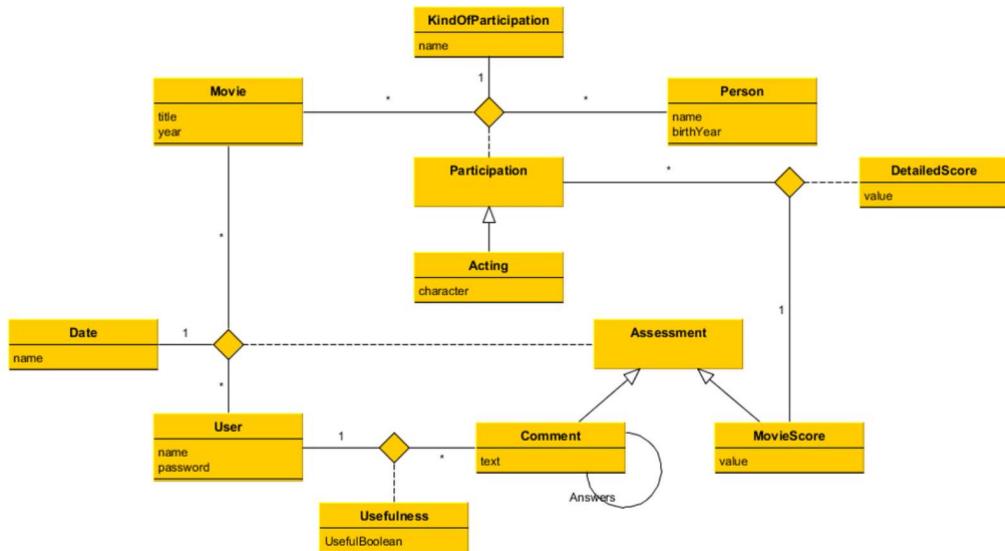
CITIZEN SECURITY

DISTRICTS	RELATED TO PEOPLE	RELATED TO PROPERTY	WEAPON POSSESSION	DRUG POSSESSION	DRUG CONSUMPTION
CENTRO	48	127	10	190	82
ARGANZUELA	61	45	3	10	6
RETIRO	0	19	4	12	0
SALAMANCA	18	58	0	7	0
CHAMARTÍN	12	29	0	16	9

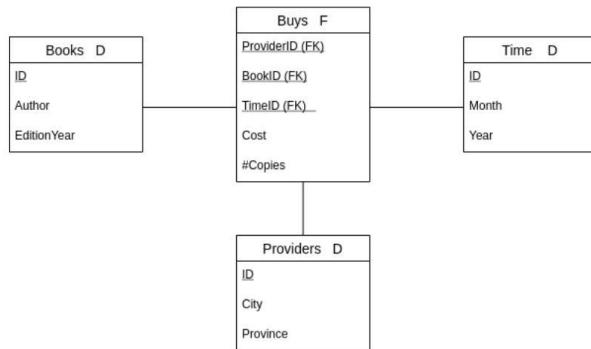
Una solución posible puede ser la tabla de hechos **Detención** con el número de identificador del delito y las tablas de **Distrito** y **Tipo** como dimensiones. Eso sí, si se añade un nuevo tipo de delito, se tiene que añadir a la tabla de hechos.

Sino podría ser la tabla de hechos **Detención** con todos los tipos de delitos como variables booleanas y únicamente la tabla **Distrito** como dimensión.

3. Identify some multidimensional schema (i.e., fact subject of analysis and its corresponding analysis dimensions) in the next UML class diagram.



5. Given the multidimensional schema, the sequence of multidimensional operations below, and the equivalent SQL query, justify if they correspond to each other. If they don't, briefly explain why and how the SQL query should be fixed.



- A:=Roll-up(Buys, Providers.city, Sum)
- B:=Roll-up(A, Books.AllBooks, Sum)
- C := Roll-up(B, Time.AllDays, Sum)
- D := ChangeBase (C, { Providers })
- E:=Selection(D, city="Barcelona")
- F := Projection(E, #copies)
- R := Drill-down(F, Providers.ID)

```

SELECT bo.ID, t.ID, p.City, SUM(bu.cost)
FROM Books bo, Buys bu, Providers p, Time t
WHERE bu.BooksID = bo.ID AND bu.TimeID = t.ID AND bu.ProviderID = p.ID
GROUP BY bo.ID, t.ID, p.City
ORDER BY bo.ID, t.ID, p.City;
  
```

```

SELECT 'Allbooks', t.ID, p.City, SUM(bu.cost), SUM(bu.copies)
FROM Books bo, Buys bu, Providers p, Time t
WHERE bu.BooksID = bo.ID AND bu.TimeID = t.ID AND bu.ProviderID = p.ID
GROUP BY t.ID, p.City
ORDER BY t.ID, p.City;
  
```

```

SELECT 'Allbooks', 'Alldays', p.City, SUM(bu.cost), SUM(bu.copies)
FROM Books bo, Buys bu, Providers p, Time t
WHERE bu.BooksID = bo.ID AND bu.TimeID = t.ID AND bu.ProviderID = p.ID
GROUP BY p.City
ORDER BY p.City;
  
```

```

SELECT p.City, SUM(bu.cost), SUM(bu.copies)
FROM Books bo, Buys bu, Providers p, Time t
WHERE bu.BooksID = bo.ID AND bu.TimeID = t.ID AND bu.ProviderID = p.ID
GROUP BY p.City
ORDER BY p.City;
  
```

```

SELECT p.City, SUM(bu.cost), SUM(bu.copies)
FROM Books bo, Buys bu, Providers p, Time t
  
```

```

WHERE bu.BooksID = bo.ID AND bu.TimeID = t.ID AND bu.ProviderID = p.ID
AND p.City = 'BARCELONA'
GROUP BY p.City
ORDER BY p.City;

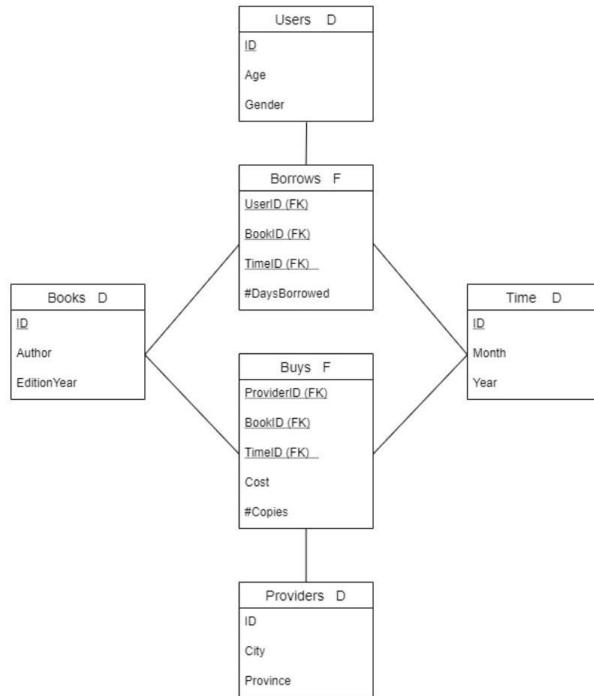
SELECT p.City, SUM(bu.copies)
FROM Books bo, Buys bu, Providers p, Time t
WHERE bu.BooksID = bo.ID AND bu.TimeID = t.ID AND bu.ProviderID = p.ID
AND p.City = 'BARCELONA'
GROUP BY p.City
ORDER BY p.City;

SELECT p.ID, SUM(bu.copies)
FROM Books bo, Buys bu, Providers p, Time t
WHERE bu.BooksID = bo.ID AND bu.TimeID = t.ID AND bu.ProviderID = p.ID
AND p.City = 'BARCELONA'
GROUP BY p.ID
ORDER BY p.ID;

SELECT p.ID, SUM(bu.copies)
FROM Buys bu, Providers p
WHERE bu.ProviderID = p.ID AND p.City = 'BARCELONA'
GROUP BY p.ID
ORDER BY p.ID;

```

6. Write multidimensional queries using the following constellation schema and the steps required in each exercise:



- A:=Roll-up(borrows, Users.Gender, Sum)
 - B:=Roll-up(A, Time.Month, Sum)
 - R:=Selection(B, Time.Month='January')

```

SELECT u.Gender, b.BookID, t.Month, SUM(b.#DaysBorrowed)
FROM Borrows b, Time t, Users u
WHERE b.UserID = u.ID AND b.TimeID = t.ID AND t.Month = 'January'
GROUP BY u.Gender, b.BookID, t.Month
ORDER BY u.Gender, b.BookID, t.Month

```

- A:=Roll-up(buys, Providers.AllProviders, Sum)
 - B:=Roll-up(A, Books.Allbooks, Sum)
 - C := Roll-up(B, Time.AllDays, Sum)
 - D := ChangeBase (C, { Providers })
 - R := Projection(D, #Copies)

```

SELECT 'AllProviders', SUM(bu.#copies)
FROM Buys bu

```

- A:=Roll-up(borrows, Users.AllUsers, Sum)
 - B:=Roll-up(A, Books.EditionYear, Sum)
 - C := ChangeBase(B, { Books, Time })
 - D := Drill-across (C, buys)
 - R := Projection(D, Cost)

```

SELECT bo.EditionYear, b.TimeID, ('AllProviders',) SUM(bu.Cost)
FROM Borrows b, Books bo, Buys bu
WHERE b.BookID = bo.ID AND b.BookID = bu.BookID AND b.TimeID = bu.TimeID
GROUP BY bo.EditionYear, b.TimeID
ORDER BY bo.EditionYear, b.TimeID

```

- A:=Roll-up(buys, Providers.AllProviders, Sum)
 - B := ChangeBase (A, { Books, Time })
 - C := Drill-across (B, borrows, Sum)
 - D:=Projection(C, #Daysborrowed)
 - R:=ChangeBase(D, { Books, Time, Users })

```

SELECT b.BookID, b.TimeID, 'AllUsers', SUM(b.#DaysBorrowed)
FROM Buys bu, Borrows b
WHERE b.BookID = bu.BookID AND b.TimeID = bu.TimeID
GROUP BY b.BookID, b.TimeID
ORDER BY b.BookID, b.TimeID

```

Hay que mirar el nivel de agregación (los atributos de agregación en el GROUP BY). Como userID no aparece, el nivel de agregación es AllUsers. Se pueden eliminar las dimensiones porque la relación es de FK y PK y no hay diferencias de tuplas.

- A:=Roll-up(borrows, Time.Month, Sum)
 - B:=Selection(A, Time.Month='January')
 - R:=Drill-down(B, Time.Id)

```

SELECT b.BookID, t.ID, b.UserID, SUM(b.#DaysBorrowed)
FROM Borrows b, Time t
WHERE b.TimeID = t.ID AND t.Month = 'January'
GROUP BY b.BookID, t.ID, b.UserID
ORDER BY b.BookID, t.ID, b.UserID

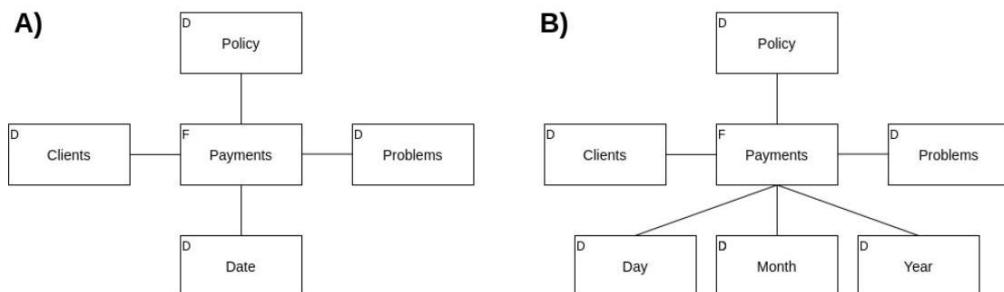
```

7. Identify the problem in this sequence of algebraic multidimensional operations, and briefly explain how you would solve it.

- A:=Roll-up(Sales, Providers.Province, Sum)
- B := ChangeBase(A, { Books, Time })
- C := Drill-across(B, Loans, Sum)
- D := Projection(C, days)
- R:=ChangeBase(D, { Books, Time, Users })

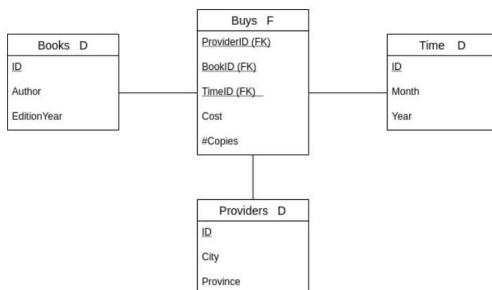
En el primer cambio de base para obtener B, la dimensión Providers tendría que ser una constante (el nivel mas alto de la jerarquía de agregación 'AllProviders', granularidad más baja) para poder realizar su eliminación.

8. Which schema of options A and B would you choose and why:



Escogería el esquema de estrella A ya que nos evitamos hacer más joins. Las tablas de Dia, Mes y Año están juntas en una sola tabla de Fecha. Aunque se repitan muchos datos es la mejor opción. Tiene algunos problemas ya el número de filas de la tabla de Fecha puede aumentar bastante, pero no superaría la cantidad de datos de la tabla de hechos.

9. Given the multidimensional schema and the sequence of multidimensional operations below, give the equivalent SQL query (simplify it as much as possible).



- A:=Roll-up(Buys, Providers.AllProviders,Sum)
- B:=Roll-up(A, Books.AllBooks,Sum)
- C:=Roll-up(B, Time.AllDays,Sum)
- D := ChangeBase (C, { Providers })
- E := Projection(D, #copies)
- R:=Drill-down(E, Providers.City)

```

SELECT p.City, SUM(bu.copies)
FROM Providers p, Buys bu
WHERE p.ID = bu.ProviderID
GROUP BY p.City
ORDER BY p.City;

```

10. Give the relational representation (i.e., tables and their corresponding integrity constraints) of the geographical dimension for a data mart in United Nations, so that it allows to keep track of changes in territories. Assume you only need to keep track of countries and their first administrative level (e.g., Autonomous communities in Spain). We would like to consider the split of countries (like in the case Catalonia would become independent), as well as annexations (like the case of Crimea peninsula by Russian Federation, assuming that peninsula was already a pre-existing component of Ukraine at the first administrative level). Briefly justify your answer and explicit any assumption you make.

Territories (Country, FAL)

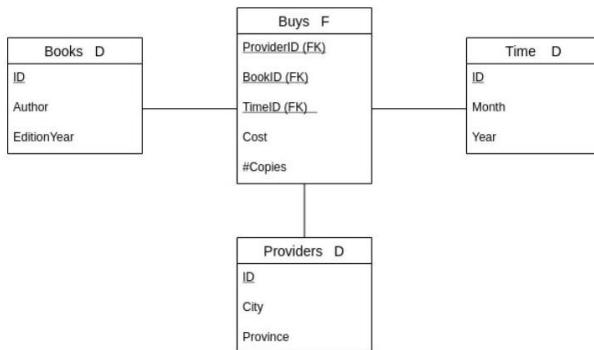
Tenemos diferentes opciones, una de ellas es añadir una columna para cuando haya un cambio en los territorios. En el caso que haya cambiado esa columna tendría el valor anterior y en el caso que no tendría valor null.

Territories (Country, FAL, OldFAL)

Otra opción sería añadir el campo de valid time para saber cuando se ha producido el cambio y poder ver la evolución, este caso es más difícil pero generaliza mejor, podemos poner más cambios.

Territories (Country, FAL, ValidTime)

11. Given the multidimensional schema and the sequence of multidimensional operations below, give the equivalent SQL query (simplify it as much as possible).



- A:=Projection(Buys, Cost)
- B:=Roll-up(A, Providers.Province, Sum)
- C := Selection(B, Province='Barcelona')
- D:=Drill-down(C, Providers.City, Sum)
- E:=Selection(D, TimeID='20210115')
- R:=ChangeBase(E, { Providers, Books })

```

SELECT bo.ID, t.ID, p.City, SUM(bu.cost)
FROM Books bo, Time t, Providers p, Buys bu
WHERE bo.ID = bu.BookID AND t.ID = bu.TimeID AND p.ID = bu.ProviderID
AND p.Province = 'BCN' AND t.TimeID = '20210115'
GROUP BY bo.ID, t.ID, p.City
ORDER BY bo.ID, t.ID, p.City;

```

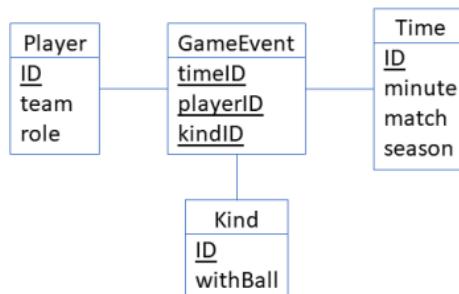
No se puede hacer el cambio de base ya que la dimensión de Time no está en la jerarquía de agregación más alta ('AllTime').

12. Identify the main problem in the multidimensional schema below, and propose a solution to solve it. You should assume athletes do not change the club in the middle of the year.

D		F	D
Club	Athlete	Year	Year
FCB	Leo Messi	2020	30M€
...	Rafa Nadal	2020	34M€

El principal problema, desde un punto de vista relacional, es que hay una violación de la clave foránea ya que esta es NULL, no puede ser ya que la clave primaria a la que referencia no puede ser NULL. Hay un error de completez, deberíamos añadir valores ficticios para que cuando agreguemos de el valor correcto. Por ejemplo si agregamos el income por clubes no nos dará el valor total de income ya que hay deportistas que no tienen equipo. Deberíamos añadir a los deportistas individuales un valor fantasma como 'Individual' en la tabla que apunte a la dimensión.

13. The multidimensional schema below corresponds to events in football matches with and without ball (e.g., pass, tackling) involving players with any role in the team (e.g., goalkeeper, defender). Write a cube-query (SQL) over it. If you cannot do it, briefly explain why.



No tiene atributos en la tabla de hechos, no da información . P.e no podemos hacer agregaciones. Podemos contar número de faltas, goles, etc. (*factless fact*). Pero ninguna consulta más.

Appendix C Extraction, Transformation and Load

C.1 Theoretical questions

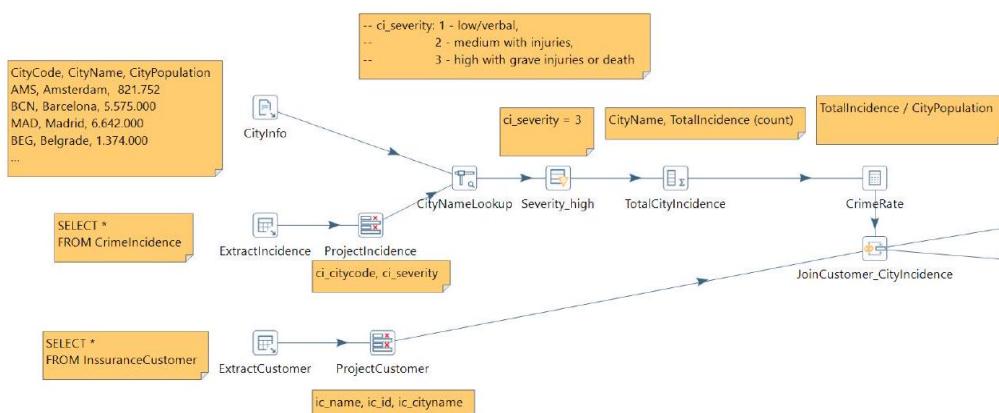
1. Name three extraction mechanisms using exclusively the DBMS and briefly explain the requirements each of these pose on it.
 - **Trigger-based**
 - **Log-based:** dietario donde se guardan todas las operaciones de la base de datos por si se va la luz de manera que se puede reejecutar todo.
 - **Timestamp:** Si estamos delante una BD temporal y tiene una gestión de datos temporal podemos ver qué se ha modificado desde la última carga que hicimos en el DW.

2. Name three advantages of creating ETL processes using ETL tools (against hand-coded scripts).
 - **Repositorio de metadatos integrado**
 - **Análisis automático de la línea de datos y dependencias**
 - **Manejo de dependencias complejas y manejo de errores**

3. Which ETL process quality characteristic is primarily improved by introducing Logical and Conceptual designs? Briefly explain how.
 Sobre todo al mantenimiento de la BD. Un poco también la auditabilidad ligada a que se entiendan mejor las cosas. Al rendimiento y a la robustez no ayuda.

C.2 Problems

1. A worldwide life insurance company, performs periodically a check for all its customers of the crime rate in their city of residence (by using an external DB with CrimeIncidence registry) in order to adapt their policies accordingly.
 - The first problem is that the CrimeIncidence registry is using city codes, while the company's Customer DB table stores city names instead.
 - The company is specifically interested in high severity incidences (those that can yield in customer death).
 - The CrimeRate is calculated as the total number of incidences in the city divided by the city's population.



a. Propose possible performance optimizations of the ETL flow.

- i. Considering that the Incidence DB does not provide any query mechanism (it only provides reading the entire incidence registries).

Como el `join` es la operación más cara, filtrar por `ci_severity` antes de realizar el `join`. Hacer el conjunto de datos los más pequeño posible y lo antes posible.

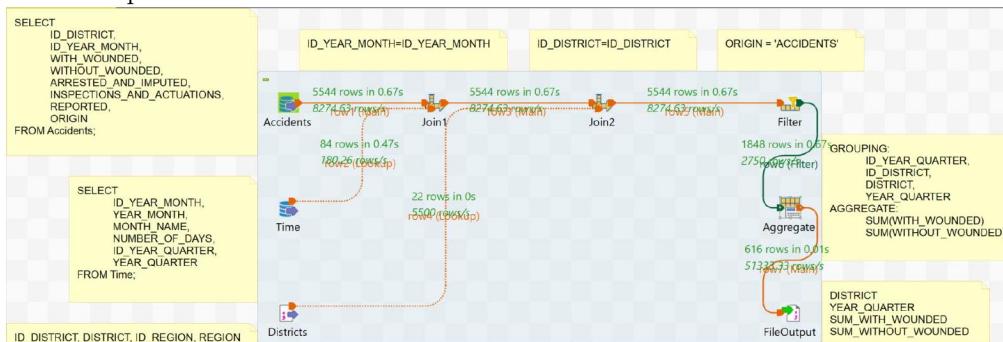
Podemos cambiar también el `groupby`. Mirando que el nombre de la ciudad viene definido por el `ci_citycode`, se puede modificar el `groupby` en función del `ci_citycode` para moverlo antes del `join` y después del filtrado.

ii. Exploiting the functionalities of the source DBMS engine.

La selección (filtrado) en vez de ponerla en la rama ponerla directamente en la BD. Le pedimos al BD que nos envíe los datos que toquen. Pasa lo mismo con las proyecciones, no tiene sentido cargar atributos para después eliminarlos. Nos quedamos solo con los atributos que sean útiles. Si se puede reducir el número de filas y de columnas antes de cargar los datos mucho mejor. Esto no se puede hacer con ficheros. El GROUP BY también lo podemos poner dentro del SGBD. Esto es más discutible. Hacer una selección/proyección es "gratis", en cambio hacer el GROUP BY requiere memoria que tenemos que dedicar a realizar esta consulta. Por lo tanto hacerlo en el servidor tiene un coste, este servidor es nuestro o no lo es? el servidor se esta ahogando? puede ser que estemos afectando a otros usuarios. Lo mismo pasa con las joins.

RESUMEN: intentamos reducir el numero de datos lo antes posible, las selecciones y proyecciones las ponemos lo antes posible y otras operaciones más costosas las tendríamos que consultar con el gestor de la BD para ver si son viables.

2. Given the ETL below, where the stickers indicate the attributes and conditions of the nearest node, briefly explain how you would optimize its performance (a.k.a. execution time) or justify why you think it is already optimal. Explicit any assumption you need to make and annotate any change in the same diagram to facilitate the explanation.



Primero de todo podríamos mover el filtro por origen antes del primer join para filtrar directamente desde accidentes. De esta manera recudimos el número de filas antes de entrar al join. También podemos mover el group by antes del segundo join, puede parecer que no ya que no tenemos el atributo de District porque se obtiene de el csv Districts, pero podemos suponer que el ID_district distingue únicamente el distrito y por lo tanto podemos hacerlo. Por último también podríamos seleccionar solo los campos que necesitamos en vez de cargar tantos atributos de la BD.

Appendix D Data Quality

D.1 Problems

1. Compute the completeness ($Q_{Cm}(R)$) of the following tables:
 (a) 50%

ID	A	B	C	D	E
1	a1	b1	c1	d1	e1
2	a2	b2	c2	d2	e2
3	a3	b3	c3	d3	e3
4	a4	b4	c4	d4	e4
5	a5	b5	c5	d5	e5
6	null	b6	c6	d6	e6
7	a7	null	c7	d7	e7
8	a8	b8	null	d8	e8
9	a9	b9	c9	null	e9
10	a10	b10	c10	d10	null

(b) 90%

ID	A	B	C	D	E
1	a1	b1	c1	d1	e1
2	a2	b2	c2	d2	e2
3	a3	b3	c3	d3	e3
4	a4	b4	c4	d4	e4
5	a5	b5	c5	d5	e5
6	a6	b6	c6	d6	e6
7	a7	b7	c7	d7	e7
8	a8	b8	c8	d8	e8
9	a9	b9	c9	d9	e9
10	null	null	null	null	null

2. Compute the accuracy ($Q_A(R)$) of the following table, ignoring all attributes but A. Consider that the true value of attribute A is the inverse of the ID (i.e., ID^{-1}) and $\epsilon = 0.3$:

ID	A	B	C	D	E
1	1	b1	c1	d1	e1
2	0.9	b2	c2	d2	e2
3	0.8	b3	c3	d3	e3
4	0.7	b4	c4	d4	e4
5	0.6	b5	c5	d5	e5
6	0.5	b6	c6	d6	e6
7	0.4	b7	c7	d7	e7
8	0.3	b8	c8	d8	e8
9	0.2	b9	c9	d9	e9
10	0.1	b10	c10	d10	e10

$$\begin{aligned}
& |1/1 - 1| \leq \epsilon \\
& |1/2 - 0.9| > \epsilon \rightarrow +1 \\
& |1/3 - 0.8| > \epsilon \rightarrow +1 \\
& |1/4 - 0.7| > \epsilon \rightarrow +1 \\
& \dots \\
& Q_A(R) = 5/10 = 0.5
\end{aligned}$$

The ID's 1, 7, 8, 9 and 10 do comply with the accuracy threshold $\epsilon = 0.3$

3. Compute the timeliness ($Q_T(X)$) of each of the attributes A, B , and C of the following table, considering that A changes once per second (i.e., $f_u(v) = 1$), B changes once every 10 seconds (i.e., $f_u(v) = \frac{1}{10}$), C changes once every 100 seconds (i.e., $f_u(v) = \frac{1}{100}$); and the different values changed depending on the id of the row and the attribute $age_A(v) = id \cdot 100$ seconds, $age_B(v) = id \cdot 10$ seconds, and $age_C(v) = id$ seconds:

ID	A	B	C	D	E
1	a1	b1	c1	d1	e1
2	a2	b2	c2	d2	e2
3	a3	b3	c3	d3	e3
4	a4	b4	c4	d4	e4
5	a5	b5	c5	d5	e5
6	a6	b6	c6	d6	e6
7	a7	b7	c7	d7	e7
8	a8	b8	c8	d8	e8
9	a9	b9	c9	d9	e9
10	a10	b10	c10	d10	e10

$$Q_T(A) = \frac{1}{10} \cdot \sum_{id=1}^{10} \left(\frac{1}{1 + id \cdot 100} \right) = 0.002913$$

$$Q_T(B) = \frac{1}{10} \cdot \sum_{id=1}^{10} \left(\frac{1}{1 + id} \right) = 0.20198$$

$$Q_T(C) = \frac{1}{10} \cdot \sum_{id=1}^{10} \left(\frac{1}{1 + \frac{1}{100} \cdot id} \right) = 0.94857$$

$$Q_T(R) = \frac{1}{5} \cdot (Q_T(A) + Q_T(B) + Q_T(C) + Q_T(D) + Q_T(E))$$

4. Compute the consistency ($Q_{Cn}(R, BR)$) of the table considering the set of business rules BR contains these:
- All rows must have its id number in all the values.
 - All values in a column must start with the letter of the corresponding attribute.

ID	A	B	C	D	E
1	a1	b1	c1	d1	e10
2	a2	b2	c2	e2	e2
3	a3	b3	k5	d3	e3
4	ab	ba	c4	d4	e4
5	a5	b5	c5	d5	e5
6	a6	b6	c6	d6	e6
7	a7	b7	c7	d7	e7
8	a8	b8	c8	d8	e8
9	a9	b9	c9	d9	e9
10	a10	b10	c10	d10	e10

- **Fila 1:** no, E tiene 10 y no 1 (si se entiende el atributo como string, entonces podríamos interpretar que el valor si que contiene el 1 dentro del valor y entonces si cumpliría.)
- **Fila 2:** no, D empieza por e
- **Fila 3:** no, c empieza por k y no tiene 3
- **Fila 4:** no tiene números en A y B
- **Fila 5:** si
- **Fila 6:** si
- **Fila 7:** si
- **Fila 8:** si
- **Fila 9:** si
- **Fila 10:** si

Un 60% de las filas cumplen todas las business rules.

5. Which logic property (or properties) of data quality rules is (are) violated by the given relational schema? Briefly explain why.

```

CREATE TABLE Flights (
    flightID CHAR(26) NOT NULL,
    departureAirport CHAR(3) NOT NULL REFERENCES Airports (ID),
    arrivalAirport CHAR(3) NOT NULL REFERENCES Airports (ID)
    actualDeparture TIMESTAMP WITHOUT TIME ZONE,
    actualArrival TIMESTAMP WITHOUT TIME ZONE,
    duration INTERVAL,
    CONSTRAINT ckDepartureAirport CHECK (departureAirport <> 'BCN'),
    CONSTRAINT ckArrivalAirport CHECK (arrivalAirport = 'BCN'),
    CONSTRAINT ckMinDuration CHECK (duration > interval '02:30:00'),
    CONSTRAINT ckMaxDuration CHECK (duration < interval '01:25:00')
);

CREATE TABLE Airports (
    id CHAR(3) PRIMARY KEY,
    name VARCHAR(20),
    CONSTRAINT ckAirport CHECK (id <> 'BCN')
);

```

El esquema es satisfactible ya que podemos inserir una fila en la tabla Airports.

1. Falta *primary key* en la tabla `flights`, pero esto no afecta en nada en las propiedades lógicas (no viola ninguna de las reglas), esto no significa que esté bien.
2. Los dos últimos checks de la tabla `flights` son contradictorios, pero nos salva que `duration` puede ser `NULL` y por lo tanto podríamos insertar filas.
3. `arrivalAirport` tiene que ser BCN y hace referencia a `Airports` donde la `id` tiene que ser diferente que BCN. Nos podría salvar que se permitiesen valores nulos en `arrivalAirport` pero pone `NOT NULL`.
4. El check en `Flights` sobre que `departureAirport` sea diferente que BCN es redundante, ya que es clave foránea a `Airports` y allí ya se comprueba, por lo tanto deberíamos eliminar la constraint de la tabla `Flights`.

6. Logic properties of data quality rules:
 - (a) Which logic property (or properties) of data quality rules is (are) violated by the given relational schema? Briefly explain why.

```

CREATE TABLE Airports (
    id CHAR(3) PRIMARY KEY,
    name VARCHAR(20) NOT NULL,
    capacity INT NOT NULL,
    CONSTRAINT ckCapacity CHECK (capacity > 1200)
);

CREATE TABLE Pilots (
    id SMALLINT PRIMARY KEY,
    firstName VARCHAR(20) NOT NULL,
    lastName VARCHAR(20) NOT NULL
    hubAirport CHAR(3) NOT NULL REFERENCES Airports(id),
    CONSTRAINT ckAirportPilot CHECK (hubAirport <> 'BCN')
);

CREATE TABLE TechnicalLogBookOrders (
    workOrderID INT PRIMARY KEY,
    aircraftRegistration CHAR(6) NOT NULL,
    executionDate DATE,
    executionPlace CHAR(3) NOT NULL REFERENCES Airports(id),
    reporterID SMALLINT NOT NULL REFERENCES Pilots(id),
    reportingDate DATE,
    due DATE,
    deferred BOOLEAN,
    CONSTRAINT ckAirportOrder CHECK (executionPlace = 'BCN')
);

CREATE VIEW anonymousReports AS (
SELECT *
FROM TechnicalLogBookOrders t WHERE NOT EXISTS(
    SELECT *
    FROM Pilots b
    WHERE b.id = t.reporterID));
  
```

Las tres tablas están vivas pues se puede agregar por lo menos una fila en cada una de ellas. Las restricciones de integridad no presentan problemas. Por ende el esquema es satisfactible.

La view no está viva pues según las restricciones de las tablas, no tendrá la vista ninguna fila. Esto sucede porque en la vista se deben mostrar las filas de `t` en las cuales no haya pilotos de `t` (que hayan reportado) en la tabla `p`. Esto claramente nunca se satisface, pues el piloto de `t` referencia a la tabla `p`.

- (b) Given the relational schema above, is the state represented with the instances of the Pilots and Airports tables below, reachable? Briefly explain why.

Pilots (id, firstName, lastName, hubAirport);	Airports (id, name, Capacity)
1 Jerry Garcia BCN	BCN Barcelona-E1 Prat 1250
2 Helen Smith MAD	LHR London-Heathrow 2500
3 Susan Blair LHR	MAD Madrid-Barajas 1300

No porque la primera tupla de la tabla Pilots no cumple con la restriccion de integridad intra-tupla, pues el valor de hubAirport no puede ser 'BCN'.

7. Determine the liveliness of the next three tables. Briefly justify your answer.

```

create table Teams (
    name varchar(25),
    budget int,
    city varchar(15) not NULL,
    primary key (name),
    check (name='Futbol Club Barcelona')
);

create table Players (
    name varchar(30) not NULL,
    age int check (age>0 and age<50),
    team varchar(25) not NULL,
    number int check (number>=0 and number<100),
    primary key (name),
    foreign key (team) references teams(name)
);

create table Matches (
    local varchar(25),
    visiting varchar(25),
    primary key (local, visiting),
    foreign key (local) references teams(name),
    foreign key (visiting) references teams(name)
    check (local <> visiting)
)

```

- Teams está viva si inserimos el Barça.
- Players está viva pero tenemos que poner jugadores del Barça.
- Matches muerta ya que tanto local como visiting referencian Teams que tienen que ser el Barça, pero a la vez el check impide que jueguen Barça contra Barça.

8. For the database schema defined below, list all the Intra-Attribute, Intra-Tuple, Intra-Relation, and InterRelation integrity constraints defined in the schema.

```

CREATE TYPE FrequencyUnitsKind AS ENUM ('Flights', 'Days', 'Miles');

CREATE TABLE ForecastedOrders (
    workOrderID INT PRIMARY KEY,
    aircraftRegistration CHAR(6) NOT NULL REFERENCES Aircrafts(registration),
    deadline DATE NOT NULL,
    planned DATE NOT NULL,
    frequencyUnits FrequencyUnitsKind,
    CONSTRAINT ckAirportOrder CHECK (executionPlace <> 'BCN'),
    CONSTRAINT ckDeadline CHECK (deadline < planned)
);

CREATE TABLE Aircrafts (
    registration CHAR(6) PRIMARY KEY,
    manufacturer_serial_number CHAR(8) NOT NULL UNIQUE,
    aircraft_model VARCHAR,
    manufacturer
);

```

- **Intra-Attribute:**

- Comprobación de valores NOT NULL
- Que sean de un dominio determinado. e.g. INT, DATE.

- **Intra-Tuple:**

- El CHECK sobre executionPlace no se puede hacer ya que executionPlace no es un atributo de la tabla, sino que se refiere a un valor de ckAirportOrder. Por lo tanto solo el segundo check.

- **Intra-Relation:**

- Ambas PRIMARY KEY de las dos tablas y el UNIQUE de la relación Aircrafts.

- **Inter-Relation:**

- La FOREIGN KEY de aircraftRegistration hacia la tabla Aircrafts

9. Consider the following data sources,

- Source 1: Data from a surveillance system about the reported cases of diagnostics of a disease in a country (e.g., Rabies in South Africa).
- Source 2: Data from a medicine distribution system about the number of requested Rabies medicines from South Africa.

Which of the four metrics can we use to measure the quality of these two sources?

Comprobar que tanto los ministerios como las farmacéuticas nos dan datos presentes. Los números tendrían que coincidir, si un ministerio dice que ha enviado 5 medicamentos de la rabia a España, la farmacéutica debería poner que ha pedido 5 medicamentos. Una manera de medir esto sería medir como de cerca se encuentran estos números.

La accuracy, timeliness, etc. son métricas útiles pero no son las únicas. Hay que adaptar las métricas al problema que tenemos.

Appendix E Schema and Data Integration

E.1 Theoretical questions

1. Name the three major steps to solve semantic heterogeneity.
Schema alignment, schema mapping, entity resolution, record merging

2. Which is the main difference between a federated architecture and an architecture based on wrappers and mediators?

Wrappers esconden la complejidad. A partir de aquí todos tienen el mismo formato. El segundo paso es otra pieza de software, el **mediador**, que dados diferentes fuentes de datos y una consulta hace esta consulta global y la divide entre los diferentes data sources.

La diferencia es que en la federada es más institucional (más rígida), único esquema global al cual intentamos hacer una consulta centralizada. En la de wrappers y mediators hay más autonomía.

3. Give an example of schematic discrepancy (different from that in the slides), where data in one source is represented as metadata in the other. Draw and briefly explain it.

En *one hot encoding* convertimos datos (variables categóricas) en metadatos (columnas de categorías con valores binarios). Entonces en una tabla Jugadores se puede tener nombre, años, club, etc. En donde club contiene los diferentes **datos** de los nombres de los clubs (Barça, Madrid, etc). En cambio una representación del tipo nombre, años, Barça, Madrid presentaría a los datos de los clubs como metadatos y habría una codificación one-hot para indicar en cual de estos club esta el jugador.

4. Which is the worst-case cost of the R-Swoosh algorithm and when would it happen?

El peor caso es cuando todos tienen similitud pero no nos damos cuenta hasta el final del bucle, es decir, siempre encontramos como similar el último elemento del output.

La función de similitud se ejecuta más veces, pues la complejidad del algoritmo es cuadrática. Mientras que en el mejor caso, la función de *merge* se ejecuta tantas veces como el orden de cardinalidad de la entrada (todos coinciden).

E.2 Problems

1. Suppose that there are two dealers A and B, who respectively use the schemas:

Dealer A

Cars(serialNo, model, color, autoTrans, navi)

Dealer B

Autos(serial, model, color)

Options(serial, option), serial is FK to Autos

We define a global schema like the first one, except that we record the option of having an automatic transmission, and we include an attribute

that tells which dealer has the car.

```
AutosGlobal(serialNo, model, color, autoTrans, dealer)
```

a) Which queries should be issued to each wrapper to answer:

```
SELECT serialNo, model  
FROM AutosGlobal  
WHERE color=' red',
```

Dealer A:

```
SELECT c.serialNo, c.model  
FROM Cars c  
WHERE c.color= 'red'
```

Dealer B:

```
SELECT a.serial, a.model  
FROM Autos a  
WHERE a.color= 'red'
```

b) If dealer A wants to insert a new row through the global schema, what SQL insert statements should it use?

```
INSERT INTO AutosGlobal VALUES (serialNox, modelx, colorx,  
autoTransx, 'Dealer A')
```

c) Suppose now that dealer A records 0 or 1 in attribute autoTrans, while the global schema needs to show respectively 'no' or 'yes' for the same attribute. Show how the translation from Cars to AutosGlobal could be done by an SQL query.

```
SELECT c.serialNo, c.model, c.color,  
CASE WHEN c.autoTrans = 1 THEN 'yes' ELSE 'no' END,  
'Dealer A'  
FROM Cars c
```

d) Assuming that a query just passes through the wrapper unchanged until it reaches the relational data source, what would a mediator do in the presence of the following queries (although a mediator is not necessarily implemented in SQL, you can express this answer in terms of SQL):

i. Find the serial numbers of cars with automatic transmission.

```
SELECT c.serialNo AS serialNo  
FROM Cars c  
WHERE c.autoTrans = 1  
UNION  
SELECT o.serial AS serialNo  
FROM Options o  
WHERE o.option = 1
```

ii. Find the serial numbers of cars without automatic transmission

```
SELECT c.serialNo AS serialNo  
FROM Cars c
```

```

WHERE c.autoTrans = 0
UNION
SELECT o.serial AS serialNo
FROM Options o
WHERE o.option = 0

```

iii. Find the serial number of the blue cars from dealer A.

```

SELECT c.serialNo AS serialNo
FROM Cars c
WHERE c.color = 'Blue'

```

e) Suppose now that we have a semantic heterogeneity in the extension of the attribute color, and it is not codified in the same way in the local schema of Dealer A and the global schema. Assuming that we have a relation GtoL(globalColor, localColor),³ that translates between the two sets of colors, modify the following wrapper template appropriately:

Template	Query
<pre> SELECT c.serialNo, c.model, g.globalcolor, c.autoTrans, 'DealerA' FROM Cars c, GtoL g WHERE c.color = g.localColor AND g.globalColor='\\$c'; </pre>	<pre> SELECT serialNo, model, color, autoTrans, 'dealerA' FROM AutosGlobal WHERE color='\\$c'; </pre>

2. Computer company A keeps data about the PC models it sells in the schema:

```

Computers(number, proc, speed, memory, hd)
Monitors(number, screen, maxResX, maxResY)

```

For instance, the tuple [123, Athlon64, 3.1,512,120] in Computers means that model 123 has an Athlon 64 processor running at 3.1 gigahertz, with 512Mb of memory and 120 Gb hard disk. The tuple [456, 19, 1600, 1050] in Monitors means that model 456 has a 19 -inch screen with a maximum resolution of 1600×1050 .

Computer company B only sells complete systems, consisting of a computer and monitor. Its schema is:

```
Systems(id, processor, mem, disk, screenSize)
```

The attribute processor is the speed in gigahertz; the type of processor (e.g., Athlon 64) is not recorded. Neither is the minimum and maximum resolution of the monitor recorded. Attributes id, mem, and disk are analogous to number, memory, and hd from company A, but the disk size is measured in Mb instead of Gb.

a) Suggest two other schemas (substantially different but not adding more information) that computer companies C and D might use to hold data like that of companies A and B.

C: ComputerPack(number, proc, speed, memory, hd, screen, maxResX, maxResY)

D: Systems(id, processorID, hd, sceenSize)
Processor(ID, speed, memory)

b) Suppose now that we have three wrappers, one for Computers and one for Monitors, in company A, and one for Systems in company B. Which queries should be issued by each wrapper to answer:

i. Find the system with 512Mb of memory, an 80 Gb hard disk, and a 22 inch monitor.

Computers

```
SELECT c.number  
FROM Computers c  
WHERE c.memory = 512 AND c.hd = 80
```

Monitors

```
SELECT m.number  
FROM Monitors m  
WHERE m.screen = 19
```

Systems

```
SELECT s.id  
FROM Systems s  
WHERE s.mem = 512 AND s.disk = 81,920 AND s.sceenSize = 19
```

ii. Find the system with a Pentium-IV processor, running at 3.0 gigahertz with a 22 -inch monitor and a maximum resolution of 1600-by-1050.

Computers

```
SELECT c.number  
FROM Computers c  
WHERE c.proc = 'Pentium-IV' AND c.speed = 3.0
```

Monitors

```
SELECT m.number  
FROM Monitors m  
WHERE m.screen = 22 AND m.maxResX ≤ 1600 AND m.maxResY ≤ 1050
```

Systems

```
SELECT s.id  
FROM Systems s  
WHERE s.sceenSize = 22 AND s.processor = 3
```

iii. Find all systems with a G5 processor running at 1.8 gigahertz, with 2 gigabytes of memory, a 300 gigabyte disk, and a 19-inch monitor.

Computers

```
SELECT c.number
FROM Computers c
WHERE c.proc = 'G5' AND c.speed = 1.8 AND c.memory = 2 AND c.hd
= 300
```

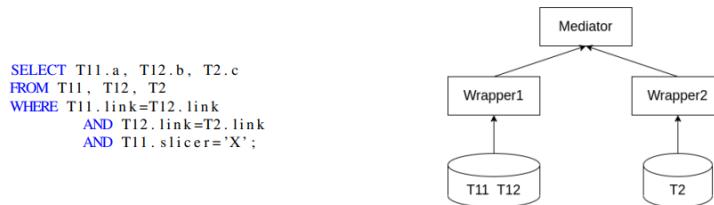
Monitors

```
SELECT m.number
FROM Monitors m
WHERE m.screen = 19
```

Systems

```
SELECT s.id
FROM Systems s
WHERE s.processor = 1.8 AND s.mem = 2 AND s.disk = 300 AND
s.screenSize = 19
```

3. We want to gain integrated access to two databases (DB1 and DB2). The former contains two tables (T11 and T12), while the later contains only one table (T2). In order to implement this, we think that the best architecture is having two wrappers and one mediator, just like depicted in the figure.



Fill the following table expliciting for each necessary call (having 5 gaps does not mean there must be exactly 5 calls) to obtain the result of the query above, who is in charge of its execution (either the mediator or one of both wrappers) and the corresponding SQL query. Write the calls following their execution order.

³³ Notice that globalColor and localColor are both alternative keys of the table and hence their relationship is one-to-one.

Order	Executor	SQL sentence
1	Wrapper1	SELECT T11.a, T12.b, T12.link FROM T11, T12 WHERE T11.link = T12.link AND T11.slicer = X
2	Wrapper2	SELECT T2.c, T2.link FROM T2
3	Mediator	SELECT W1.a, W1.b, W2.c FROM Wrapper1 W1, Wrapper2 W2 WHERE W1.link = W2.link

4. Consider an integrated system with two different sources (e.g., Vueling-V and Airbus-A). The tables are the following and the mapping between the local and global schemas is given using GAV with relational algebra expressions as follows ("get_date" is a function with the obvious meaning):

Vueling: Hops(from, to, timestamp, plane, mainIncident)

Airbus: Planes(registry, sits)

- Flights(origin, destination, day, aircraft) := V.Hops[from,to,get_date(timestamp),plane]
- Incidents(aircraft,day, ATACode) := V.Hops[plane,get_date(timestamp), mainIncident]
- Aircrafts(aircraft,capacity) := A.Planes[registry, sits]

Assuming that both databases reside in the same RDBMS (i.e., wrappers are not needed), give the SQL query generated by the mediator on receiving the following global one:

```
SELECT DISTINCT f.day, f.aircraft
FROM Aircrafts a
JOIN Flights f ON a.aircraft = f.aircraft
JOIN Incidents i ON f.aircraft = i.aircraft AND f.day=i.day
WHERE a.capacity >200 AND i.ATACode=21 AND f.origin='BCN';
```

```
SELECT DISTINCT get_date(h.timestamp) AS day, h.plane AS
aircraft
FROM Hops h JOIN Planes p ON h.plane = p.registry
WHERE p.sits > 200 AND h.mainIncident = 21 AND h.from = 'BCN'
```

5. Consider the following table with instances about mobile phones offered for sale extracted from different online retail platforms during the Black Friday promotion.

source	title	model_code	price
AMAZON	SAMSUNG GALAXY A6	SM-A60F2	225
PHONEHOUSE	HUAWEI P20 LITE		299
AMAZON	LG Q6 A		109
AMAZON	HONOR 8X 64G/4G	51092XWQ	249
PHONEHOUSE	HUAWEI P8 LITE		125
PHONEHOUSE	HUAWEI P8	ANE-LX1M235	173
AMAZON	HUAWEI MATE 20 LITE	ANE-LX28K93	320
FNAC	LG G5 SE		239.99
AMAZON	LG G7 THINQ	LGM77675GR	475
FNAC	SAMSUNG GALAXY A7	SM-A750GZ	350
AMAZON	SAMSUNG GALAXY S9+	SM-A7654DP	580
PHONEHOUSE	HONOR 8X 64GB 4GB	51092XWQ	253
BESTBUY	APPLE IPHONE XR		800
AMAZON	APPLE IPHONE XS	A1920	1066.66
AMAZON	APPLE IPHONE X	A1901	650
BESTBUY	IPHONE X	A1901	700.55
PHONEHOUSE	LG Q6 α	LGM700DSK	129
BESTBUY	HUAWEI P8L	ANE-LX1M235L	164.5
PHONEHOUSE	SAMSUNG GALAXY S9 PLUS		599
BESTBUY	SAMSUNG GALAXY S9P		585

The table contains information about the retail platform from where the data is extracted (source), the title of the product in the web page (title), a unique code of the model where available (model_code), and the offered price of the product (price). To integrate these data, the R-Swoosh algorithm is considered.

(a) The DW administrator is thinking of the possible similarity and merge functions for individual attributes of the given table. Answer the following question.

i. Without considering other attributes, is using Edit distance ⁴ on attribute title a good choice for a match function?

- A. If so, justify your answer and propose the possible threshold.
- B. If not, justify your answer.

No sería una buena idea. Por ejemplo nos gustaría unir IPHONE X con APPLE IPHONE X, cuya distancia de Edit es 5. Pero si marcamos un threshold como este hay otros modelos que identificará como similares pero que no son, como por ejemplo el caso de HUAWEI P8 con HUAWEI P8 LITE, que tienen una distancia de edit 4.

ii. Given the characteristics of the attribute `model_code`, which of the following combinations of similarity and merge functions should be used if this is the only attribute considered in the entity resolution process.

Similarity
Edit distance
Hamming distance
Substring matching ⁵
Exact string matching
Merge
Multi-valued ⁶
Source trustworthiness
Generate null ⁶

En este caso cogeríamos la combinación **Substring Matching** con **Source trustworthiness**. La primera es porque las únicas entidades que queremos juntar que son IPHONE X y APPLE IPHONE X tienen exactamente el mismo código de modelo y por lo tanto solo se detectaría como similar las que queremos (ya que las demás no coinciden). La segunda es porque no queremos tener valor multi valued ni tampoco generar un valor nulo por lo tanto cogeremos el valor de la fuente que sea más confiable.

iii. For the attribute `price`, the DW administrator proposed $\frac{\min(r,s)}{\max(r,s)}$ as the similarity function. Thus, we could decide that two records match even if the price does not (but its metric is high enough). Hence, we need a representative for the result of the merge. For each of the following merge functions, explain if it can be used in the R-Swoosh algorithm with the above match function. Justify your answer and if negative, elaborate what consequences it would have.

Merge	Answer (yes/no)	Justification
Mean (average)	no	Si cogemos la media puede ser que el valor que pongamos sea mayor del
Max/Min	sí	Ponemos el máximo por si acaso, el mínimo no por la razón de arriba

También se puede llegar a la conclusión que si la métrica es lo suficientemente alta (precios muy parecidos) tanto mean, max, min se podrían aplicar ya que darían valores similares.

³⁴ https://en.wikipedia.org/wiki/Levenshtein_distance

⁴ Similar if one string is contained inside another or viceversa (e.g., abcccd \approx bcccd)

⁶ For multi-valued attributes, consider they are similar if at least one value from the list matches.

iv. Now, the DW administrator considers that instead of using individual attributes alone in the similarity function, uses a combination of several attributes.

Attribute	Similarity function	Merge function
title	Edit distance, ⁷ with a threshold of 25%	Source trustworthiness with priority in decreasing order: PHONEHOUSE, BESTBUY, FNAC, AMAZON
model_code	Exact string matching	Keep any string
price	$\frac{\min(r,s)}{\max(r,s)}$, with a a a threshold of 90%	Multi-valued

Given that the similarity and merge functions in the table above over individual attributes, and considering data instances given in the mobile phone table, define possible combinations that can be used for entity resolution in order to merge tuples of same mobile phone models and list all offered prices for them. Give examples how these features would work.

Para el ejemplo del iphone tenemos que:

Title

$$dist(\text{IPHONE X}, \text{APPLE IPHONE X}) = \frac{\text{editDistance}(x, y)}{\max(\text{length}(x), \text{length}(y))} = \frac{5}{14} = 0.36 > 0.25$$

En este caso no las identificamos como similares.

Model code

El código A1901 es el mismo por lo tanto las detectamos como similares y nos quedamos con cualquiera.

Price

$$dist(650, 700.55) = \frac{\min(r, s)}{\max(r, s)} = \frac{650}{700.55} = 0.928 > 0.9$$

En este caso si que los consideramos similares ya que supera el threshold y cogemos los dos valores.

³⁷ Edit distance relative to the length of the strings is calculated as follows: $\frac{\text{editDistance}(x, y)}{\max(\text{length}(x), \text{length}(y))}$

6. Consider the following table with instances about travel arrangements offered for sale, extracted from different online travel platforms during the Christmas holidays promotion.

source	title	destination	duration	type	price
Viajes El Corte Ingles	The best of East Cost, NYC and Washington	New York, Washington	1 week	City trips	750€
Viajes El Corte Ingles	Classic China	Beijing, Xi'an	2 weeks	City trips, Special trips	1855€
Viajes El Corte Ingles	Bohemia of Prague	Prague, Karlovy Vary	1 week	City trips	700€
Viajes El Corte Ingles	Imperial cities	Budapest, Vienna	1 week	City trips	785€
Halcon Viajes	Circuit Italy on the ship, all inclusive	Venice, Rome, Naples, Palermo	15 days	Cruise, Special trips	2000€
Halcon Viajes	Holly Land and Jordan	Jerusalem, Amman	16 days	Special trips, Holiday specials	1800€
Halcon Viajes	New York and Maya's cost	New York, Cancun	15 days	Special trips, Holiday specials	2000€
Halcon Viajes	New York, New Year	New York, Washington	5 days	City trips, Holiday specials	600€
Halcon Viajes	Budapest	Budapest	3 days	City trips	350€
TUI travel	Journey to Jordan 1	Venice, Rome, Naples, Suez, Aqaba	21 days	Cruise, Special trips	772£
TUI travel	New York Holidays	New York	6 days	City trips	593£
TUI travel	Europe's finest	Budapest, Vienna, Prague	7 days	City trips	600£
TUI travel	Spicy Mexico	Maya's cost, Cancun	10 days	Special trips	On demand
TUI travel	Pearls of Orient	Shanghai, Beijing, Xi'an	19 days	Special trips	On demand
TUI travel	Tanzania	Dar es Salaam, Zanzibar	20 days	Special trips	1500£

The table contains information about the travel platform from where the data are extracted (source), the title of the offer in the web page, a destination of the trip which is a multivalued attribute (assuming the destination names are same in all the sources), duration where the units may vary (days/weeks), type of the offer if available - multi-valued attributed with fixed and unique type names (enum), and the offered price of the product in different currencies depending on the location of the travel agency (for some offers the price is given only on the explicit demand).

To compare similar offers, and present them jointly to the user, the R-Swoosh algorithm is considered for integrating these sources.

(a) The DW administrator is thinking of the possible similarity functions for individual attributes of the given table. Answer the following questions.

i. Would attribute title be a good choice to define the similarity function exclusively over it, without considering other attributes?

No es buena opción ya que los títulos no son los mismos para viajes iguales y difieren mucho. Por lo tanto no identificaremos el mismo objeto como similar. Un ejemplo sería para la destinación *New York, Washington* que tenemos títulos: *The best of East Cost, NYC and Washington* y *New York, New Year*.

ii. Given the characteristics of the attribute destination, which of the following similarity functions could be used. Explain the consequences of each solution.

Similarity functions
Substring matching ⁸
Exact string matching
Multi-valued ⁴

Substring matching: funcionaría bastante bien para la mayoría de los casos como New York, Washington y Beijing, Xi'an pero fallaría en casos como por ejemplo New York que lo juntaría con viajes combinados que contienen New York como New York, Cancun.

Exact string matching: funcionaría solo para los casos que las distinciones son idénticas pero se dejaría el caso de por ejemplo Beijing, Xi'an con Shanghai, Beijing, Xi'an.

Multi-valued: no funcionaría porque uniría casos como el de Venice, Rome, Naples, Palermo con Venice, Rome, Naples, Suez, Aqaba ya que tiene elementos iguales pero no son el mismo viaje. Funcionaría por eso para otros casos como cuando coinciden exactamente o el caso de Beijing, Xi'an.

iii. If possible, propose an improvement to using multi-valued matching for the destination attribute in the previous exercise.

7. Consider the two relational schemas below (primary key attributes underlined). Would the instances of these schemas represent the same reality? Briefly explain why and exemplify it.

- a) Flight(flightNum: String, origin: Airport, destination: Airport)
- b) FlightEnd(flightNum: String, type: {Origin, Destination}, place: Airport)

Sí que representan el mismo objeto del mundo real, en este caso un vuelo concreto. En el primer caso (Flight) este vuelo está definido por el aeropuerto de llegada y salida, mientras que en el segundo (FlightEnd) está definido por la ciudad de origen (Origin) y el destino (Destination). En cualquier caso, se refieren a lo mismo pero con diferentes atributos.

8. Given two book providers with the database schemas below, write one SQL sentence returning the data in both schemas and loading dimension table BooksDim (below). Specifically: ID, Author, Edition Year, NobelPrize, Genre. Consider that some books can be offered by both providers at the same time. In this case, all the attributes except the Genre should prevail from the Provider1, if available. In case Genre is not available, it should be marked as "Miscellaneous".

Provider1 schema:	Books Dimension:
<pre>CREATE TABLE P1_Books (Id INTEGER, Author VARCHAR(30), Year CHAR(4), Genre VARCHAR(15), PRIMARY KEY (Id))</pre>	<pre>CREATE TABLE BookDim (ID INTEGER, Author VARCHAR(30), EditionYear INTEGER, NobelPrize BOOLEAN, Genre VARCHAR(15), PRIMARY KEY (ID))</pre>
<pre>CREATE TABLE P1_Nobels (BookId INTEGER, Year CHAR(4), PRIMARY KEY (BookId), FOREIGN KEY (BookId) REFERENCES P1_Books (Id))</pre>	
Provider2 schema:	
<pre>CREATE TABLE P2_Books (Id INTEGER, Author VARCHAR(30), Year INTEGER, Nobel BOOLEAN, Genre VARCHAR(15), PRIMARY KEY (Id), CHECK (Year > 0 AND Year <=9999))</pre>	

`SELECT FROM P1_Books, P1_Nobels, P2_Books`